

基于多尺度状态空间融合的高维机器人轻量级世界模型

周新民^{1,2}, 余焕杰^{3†}, 张慧慧⁴, 王伟³, 陈露⁴

(1. 湖南工商大学 人工智能与机器人学院, 湖南 长沙 410205;

2. 湘江实验室, 湖南 长沙 410205;

3. 湖南工商大学 计算机学院, 湖南 长沙 410205;

4. 湖南工商大学 前沿交叉学院, 湖南 长沙 410205)

摘要: 机器人的高维状态预测面临精度与实时性的双重挑战。本文提出多尺度动力学世界模型 MS-WM, 通过慢速 SSM、快速 SSM 和局部注意力三个分支分别处理不同时间尺度的物理变化, 实现自适应多尺度建模。在 Gymnasium MuJoCo 基准的 Humanoid(348 维)、HumanoidStandup(348 维)、Ant(105 维) 和 Walker2d(17 维) 四个数据集上的多种子实验 5 个随机种子表明: MS-WM 在高维 Humanoid 上取得最优精度 ($MSE=21.00\times 10^{-2}$), 比 Transformer-WM 提升 18.8%; 在中维 Ant 上也优于所有基线。对于低维简单系统, 传统方法已足够, 表明多尺度建模对高维复杂动力学更有效。MPC 概念验证表明 MS-WM 具备世界模型的基本功能; GPU 批量并行 CEM 采样式 MPC 将控制频率提升至 10Hz 以上, 满足典型实时控制需求。

关键词: 状态空间模型; 世界模型; 状态预测; 模型预测控制; 具身智能

引用格式: 周新民, 余焕杰, 张慧慧, 等. 基于多尺度状态空间融合的高维机器人轻量级世界模型. 控制理论与应用, xxxx, xx(x): xxx – xxx

DOI: 10.7641/CTA.202x.xxxxx

代码开源: <https://github.com/SEMHAQ/MS-WM>

A Multi-Scale Dynamics World Model for High-Dimensional Robot State Prediction

ZHOU Xin-min^{1,2}, YU Huan-jie^{3†}, ZHANG Hui-hui⁴, WANG Wei³, CHEN Lu⁴

(1. School of Artificial Intelligence and Robotics, Hunan University of Technology and Business, Changsha Hunan 410205, China;

2. Xiangjiang Laboratory, Changsha Hunan 410205, China;

3. School of Computer Science, Hunan University of Technology and Business, Changsha Hunan 410205, China;

4. School of Frontier Crossover Studies, Hunan University of Technology and Business, Changsha Hunan 410205, China)

Abstract: High-dimensional state prediction for embodied intelligent robots faces the dual challenges of accuracy and real-time performance. This paper proposes the Multi-Scale Dynamics World Model MS-WM, which separately handles slow dynamics (position), fast dynamics (velocity), and instantaneous dynamics (forces) through three specialized branches: slow SSM, fast SSM, and local attention. Multi-seed experiments 5 seeds on three Gymnasium MuJoCo benchmarks Humanoid 348D, Ant 105D, Walker2d 17D show that MS-WM achieves the best accuracy on high-dimensional Humanoid ($MSE=21.00\times 10^{-2}$), 18.8% lower than Transformer-WM, and also outperforms all baselines on medium-dimensional Ant. For low-dimensional simple systems, traditional methods are sufficient, demonstrating that multi-scale modeling is more effective for high-dimensional complex dynamics. MPC proof-of-concept demonstrates the world model's planning capability; GPU-batched CEM sampling-based MPC achieves 10Hz+, meeting typical real-time control requirements.

Key words: state space model; world model; state prediction; model predictive control; embodied intelligence

Citation: X. Zhou, H. Yu, H. Zhang, et al. A multi-scale dynamics world model for high-dimensional robot state prediction. *Control Theory & Applications*, xxxx, xx(x): xxx – xxx

1 引言

具身智能的核心在于智能体通过与物理环境的实时交互来学习、进化并执行任务^[1]。机器人作为具身智能的重要载体,其高维度、强非线性及欠驱动特性使得“感知-决策-控制”的闭环实现极具挑战。其中,世界模型^[2]作为环境动力学的内部表征,其核心功能包括:(1) 给定当前状态和动作预测未来状态(状态转移建模),(2) 预测奖励信号和终止条件,(3) 基于预测能力支持规划与决策。在模型预测控制 model predictive control, MPC 框架中,世界模型通过前向模拟多步未来状态轨迹为优化求解提供动力学约束,其预测精度和推理速度直接决定了控制性能。

近年来,基于深度学习的世界模型取得了显著进展。基于循环神经网络 RNN 的方法^[3]虽然能够建模时序依赖,但存在梯度消失和长程依赖捕捉困难的问题。基于 Transformer 的方法^[4]通过自注意力机制有效解决了长程依赖问题,但其二次计算复杂度 $O(T^2)$ 在长序列场景下带来显著的计算开销。在具身智能领域,RT-2^[5]等大规模视觉-语言-动作模型展示了世界模型在机器人控制中的巨大潜力,但其庞大的参数量和计算需求使得部署在资源受限的机器人平台上面临严峻挑战。

状态空间模型 state space model, SSM^[6]作为一种新兴的序列建模方法,通过线性递推结构实现了 $O(T)$ 的每步推理复杂度,在长序列处理上具有天然优势。从 S4 的结构化参数化到 S4D^[7]的对角简化,再到 Mamba^[8]的选择性扫描机制,SSM 在语言建模等任务上已取得与 Transformer 相当的性能^[9]。

然而,将 SSM 应用于具身智能领域的世界模型构建尚处于起步阶段。现有工作主要集中在视觉感知和语言理解领域,而在机器人状态预测和控制方面的探索相对有限。近期,Mamba 策略网络^[20-21]和 SSM 时序预测^[22]等工作开始将 SSM 引入机器人和序列决策领域,但前者侧重于策略学习,后者侧重于时序数据预测,均未涉及面向机器人状态预测的世界模型构建。机器人状态预测任务面临三重挑战:状态维度高,涉及多个关节的耦合动力学;动作-状态映射具有强非线性;且控制回路要求毫秒级的推理延迟。这些特点要求世界模型在保持高预测精度的同时,具备极低的计算开销。

更重要的是,现有 SSM 方法在应用于机器人状态预测时存在根本性局限:S4D 采用固定对角状态矩阵,无法根据输入内容调整动力学特性,而机器人系统的动力学参数(如摩擦系数、惯性矩)会随关节配置和运动状态变化;Mamba 的选择性扫描机制虽然具有输入自适应能力,但其参数量和计算开销较

大,不适合资源受限的机器人部署场景。因此,设计一种既能保持对角 SSM 的计算效率、又能适应机器人动力学变化的新型 SSM 架构,是一个亟待解决的关键问题。

本文的主要贡献如下:

1) 提出多尺度动力学世界模型 MS-WM,通过慢速 SSM、快速 SSM 和局部注意力三个分支分别处理不同时间尺度的物理变化。慢速 SSM 捕捉长程依赖(如位置变化),快速 SSM 捕捉短程依赖(如速度变化),局部注意力捕捉瞬时变化(如力变化)。通过门控机制自适应融合三个分支,实现多尺度建模;

2) 在 Gymnasium MuJoCo 基准的 Humanoid(348 维)、Ant(105 维)和 Walker2d(17 维)三个数据集上进行了系统实验。多种子实验 5 个随机种子表明,MS-WM 在高维 Humanoid 上取得最优精度 ($MSE=21.00 \times 10^{-2}$),比 Transformer-WM 提升 18.8%;在中维 Ant 上也优于所有基线;

3) 首次在机器人世界模型状态预测任务上系统比较了 LSTM、Transformer、GRU、Mamba、S4D 和 MS-WM 六种序列模型,揭示了多尺度建模对高维复杂动力学更有效的规律;

4) 将 MS-WM 嵌入 MPC 框架进行轨迹跟踪实验,GPU 批量并行 CEM 采样式 MPC 达到 10Hz 以上的控制频率,满足典型实时控制需求。

本文其余部分组织如下:第 2 节回顾相关工作;第 3 节介绍问题描述与预备知识;第 4 节详述所提方法;第 5 节给出实验结果与分析;第 6 节总结全文并展望未来工作。

2 相关工作

2.1 机器人世界模型

世界模型的概念最早可追溯到 Karl Friston 的主动推理理论,其核心思想是智能体通过构建环境的内部模型来进行预测和规划。在深度学习时代,Ha 和 Schmidhuber 提出了基于变分自编码器 VAE 和循环神经网络的世界模型框架,通过学习压缩的环境表征来实现策略学习。Hafner 等人^[10]提出了 Dreamer 系列方法,利用潜在动力学模型在想象中进行策略优化,在多个连续控制基准上取得了领先性能。DreamerV3^[11]进一步统一了离散和连续动作空间的处理,展示了世界模型的通用性。

在机器人领域,Michels 等人探索了利用世界模型进行视觉伺服控制。Nagabandi 等人^[12-14]将神经网络动力学模型与模型预测控制相结合,实现了机器人腿部运动的快速适应。近期,RT-2 将大规模视觉-语言模型与机器人动作空间对齐,展示了基础模型在机器人控制中的潜力。然而,这些方法普遍面临

计算开销大、难以满足实时控制要求的问题. 在高效计算方面, TinyML^[15]和模型压缩技术为资源受限平台上的深度学习部署提供了解决方案. 在仿真到真实迁移方面, 域随机化和快速电机适应 RMA 等方法缩小了仿真与真实机器人之间的差距. 世界模型在自动驾驶领域也得到了广泛关注^[16], 连续-离散状态空间模型为混合系统建模提供了新思路. 本文提出的 MS-WM 旨在以极低的计算开销实现高质量的状态预测, 为机器人状态预测提供一种轻量级 SSM-Attention 混合解决方案.

2.2 状态空间模型

状态空间模型 (SSM) 源于控制理论中的线性系统描述, 近年来在深度学习领域引起了广泛关注. Gu 等人^[17]提出的 HiPPO 框架通过最优多项式投影解决了连续时间记忆问题, 为 SSM 在序列建模中的应用奠定了理论基础. S4 通过结构化参数化解决了 SSM 在长程依赖建模中的数值稳定性问题, 在 Long Range Arena 基准上取得了突破性结果.

在 S4 的基础上, 研究者提出了多种改进方案. S4D 简化了对角 SSM 的参数化, 直接使用复数对角矩阵, 在保持性能的同时显著降低了实现复杂度. S5^[18]引入 MIMO-SSM 结构, 通过并行扫描算法实现了更高效的训练. H3^[19]结合了 SSM 与门控注意力, 在语言建模中取得了与 Transformer 相当的性能.

Mamba 是 SSM 发展的一个重要里程碑. 它引入了选择性扫描机制, 使 SSM 的状态更新能够根据输入内容动态调整, 从而在保持线性计算复杂度的同时实现了与 Transformer 相当的建模能力. Mamba 的块结构已成为现代 SSM 架构的标准设计模式. Mamba-2 进一步揭示了 SSM 与注意力机制之间的结构化状态空间对偶性, 为统一理解不同序列建模方法提供了新的理论框架.

然而, 现有 SSM 方法在应用于机器人状态预测时存在局限性. S4D 采用固定对角参数化, 无法根据输入内容调整动力学特性; Mamba 的选择性扫描机制虽然具有输入自适应能力, 但其参数数量和计算开销较大. 本文提出的 MS 通过轻量级自适应网络使对角状态矩阵能够根据输入内容动态调整, 在保持对角 SSM 计算效率的同时实现了输入自适应的状态转移建模. 与 Mamba 的全参数选择性扫描不同, MS 仅对对角元素进行自适应调整, 参数数量和计算开销远小于 Mamba, 更适合资源受限的机器人部署场景.

近期, SSM 类方法也开始在机器人领域得到应用. 在策略学习方面, Mamba 被用于替代 Transformer 作为策略网络的主干, 实现了更高效的序列

决策, 其中 Mamba 策略网络在连续控制任务中取得了与 Transformer 策略网络相当的性能, 但推理速度提升了 2–3 倍. 在时序预测方面, SSM 被用于长程多变量时序预测, 利用其线性复杂度和长程建模优势. 在世界模型方面, Dreamer 系列和 TD-MPC 等方法主要基于循环神经网络或潜在动力学模型进行环境建模, 且主要面向视觉输入, 计算开销较大. 近期, RoboMamba^[23]将 Mamba 与视觉编码器结合用于机器人操作, 但其侧重视觉-语言理解而非状态空间的动力学建模.

表 1 总结了本文与上述相关工作的关键差异. 与 Mamba 策略网络相比, MS-WM 聚焦于世界模型的状态转移预测而非策略学习; 与时序预测方法相比, MS-WM 面向机器人状态-动作序列的特定结构; 与 RoboMamba 相比, MS-WM 处理低维状态向量而非视觉输入, 且通过 MPC 框架验证了规划能力. 更重要的是, MS-WM 采用多尺度融合架构而非单一的 SSM 或 Transformer, 这一设计选择在表达能力和计算效率之间取得了更好的平衡.

表 1 本文与相关工作的关键差异对比

Table 1 Key differences between this work and related works

方法	任务	输入	架构	MPC 验证
Mamba 策略	策略学习	状态-动作	选择性扫描	否
时序预测	时序预测	多变量	选择性扫描	否
RoboMamba	操作	视觉-语言	选择性扫描	否
Dreamer	世界模型	视觉	RNN	是
TD-MPC	世界模型	状态-动作	MLP	是
MS-WM (本文)	世界模型	状态-动作	多尺度融合	是

本文聚焦于状态-动作序列的世界模型构建, 区别于上述视觉输入的世界模型和策略网络方法, MS-WM 以极低的参数开销实现状态转移预测, 并通过 MPC 框架验证了其在规划决策中的可行性.

2.3 轻量级模型与实时控制

在资源受限的机器人平台上部深度部署深度学习模型是一个重要挑战. 知识蒸馏、模型剪枝和量化是常用的模型压缩方法. 网络架构搜索 NAS 也被用于自动设计高效的网络结构. 然而, 这些方法通常是事后压缩, 可能导致性能损失.

从架构设计角度出发, 门控循环单元 GRU 通过简化 LSTM 的门控结构减少了参数数量. 时间卷积网络 TCN 利用因果卷积和膨胀卷积实现了高效的序列建模. SSM 类方法通过线性递推结构实现了 $O(T)$ 的每步推理复杂度和 $O(1)$ 的单步延迟, 在长序列场景下具有显著的计算优势. 本文的 MS-WM 直接从轻量级架构设计出发, 无需额外的压缩步骤即可满足实时控制要求.

2.4 模型预测控制与学习模型

模型预测控制 (MPC) 是一种基于模型的优化控制方法, 通过在每个控制时刻求解有限时域优化问题来确定最优动作. MPC 的核心在于动力学模型的准确性: 模型越精确, 控制性能越好. 传统的 MPC 使用解析模型, 但在复杂环境中获取精确的解析模型往往困难重重.

将学习模型与 MPC 结合是一个活跃的研究方向. Nagabandi 等人展示了神经网络动力学模型在 MPC 中的有效性. Chua 等人^[24]提出了 PETS 方法, 通过概率集成模型处理模型不确定性. Hafner 等人的 Dreamer 方法则将潜在动力学模型与 MPC 相结合. 本文将 MS-WM 嵌入 MPC 框架, 利用其快速推理能力实现高频控制回路^[25].

3 问题描述与预备知识

3.1 世界模型问题描述

设机器人在时刻 t 的状态为 $\mathbf{s}_t \in \mathbb{R}^{d_s}$, 执行的动作作为 $\mathbf{a}_t \in \mathbb{R}^{d_a}$. 状态向量包含机身位置、速度、朝向及各关节角度、角速度等信息, 动作向量对应各关节的力矩或目标位置. 世界模型的目标是学习状态转移函数:

$$\mathbf{s}_{t+1} = f(\mathbf{s}_t, \mathbf{a}_t), \quad (1)$$

使得给定历史观测序列 $\{\mathbf{s}_{0:T}, \mathbf{a}_{0:T-1}\}$, 能够预测未来 H 步的状态轨迹 $\hat{\mathbf{s}}_{T+1:T+H}$. 在实际应用中, 状态转移函数 f 通常具有高维、非线性和耦合的特性.

3.2 状态空间模型

连续时间状态空间模型定义为:

$$\dot{\mathbf{h}}(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t), \quad (2)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{h}(t) + \mathbf{D}\mathbf{x}(t), \quad (3)$$

其中 $\mathbf{h}(t) \in \mathbb{R}^N$ 为隐状态, $\mathbf{x}(t)$ 为输入, $\mathbf{y}(t)$ 为输出, $\mathbf{A} \in \mathbb{R}^{N \times N}$, $\mathbf{B} \in \mathbb{R}^{N \times 1}$, $\mathbf{C} \in \mathbb{R}^{1 \times N}$, $\mathbf{D} \in \mathbb{R}$ 为系统参数.

经零阶保持离散化后, SSM 可表示为:

$$\mathbf{h}_k = \bar{\mathbf{A}}\mathbf{h}_{k-1} + \bar{\mathbf{B}}\mathbf{x}_k, \quad (4)$$

$$\mathbf{y}_k = \mathbf{C}\mathbf{h}_k + \mathbf{D}\mathbf{x}_k, \quad (5)$$

其中 $\bar{\mathbf{A}} = \exp(\Delta\mathbf{A})$, $\bar{\mathbf{B}} = (\Delta\mathbf{A})^{-1}(\exp(\Delta\mathbf{A}) - \mathbf{I}) \cdot \Delta\mathbf{B}$, Δ 为采样步长.

SSM 支持两种计算模式: 递推模式以 $O(TN)$ 的时间复杂度逐步计算, 具有 $O(1)$ 的单步延迟, 适合在线推理; 卷积模式通过 FFT 在 $O(T \log T)$ 时间内并行计算全部输出, 适合批量训练和长序列推理. 本文选择卷积模式进行推理的原因如下: 一方面, MPC 内层优化需要在同一时刻对动作序列进行多

次前向传播经 50 次 Adam 迭代, 卷积模式的批量处理能力可充分利用 GPU 并行计算; 另一方面, 卷积模式在长序列下的实际吞吐量高于递推模式. 值得注意的是, 在部署阶段若仅需单步预测, 可切换至递推模式以获得 $O(1)$ 的单步延迟.

3.3 对角 SSM 与 S4D 参数化

S4D 提出将状态矩阵 $\mathbf{A}$ 约束为对角形式:

$$\mathbf{A} = \text{diag}(a_1, a_2, \dots, a_N), \quad (6)$$

其中 $a_n = -\exp(\alpha_n) + j\beta_n$ 为复数对角元素, $\alpha_n > 0$ 确保系统的渐近稳定性. 在此参数化下, SSM 的离散化系数可解析计算:

$$\bar{a}_n = \exp(\Delta \cdot a_n), \quad \bar{b}_n = \frac{\exp(\Delta \cdot a_n) - 1}{a_n}. \quad (7)$$

对角 SSM 的输出可通过全局卷积核高效计算:

$$K[t] = \sum_{n=1}^N C_n \cdot \bar{b}_n \cdot \bar{a}_n^t, \quad t = 0, 1, \dots, T-1, \quad (8)$$

其中 $K \in \mathbb{R}^T$ 为卷积核. 该卷积可通过快速傅里叶变换 (FFT) 在 $O(T \log T)$ 时间内计算.

4 MS-WM 方法

4.1 整体架构

本文提出的 MS-WM 是一种基于融合状态空间模型 (MS) 的轻量级世界模型. MS 的核心思想是将 SSM 的长程建模能力与注意力机制的精细特征提取能力相结合, 通过自适应门控机制动态融合两个分支的输出. MS-WM 的整体架构如图 1 所示, 主要包含三个模块: 状态-动作编码器、MS 主干网络和状态解码器.

4.2 编码器与解码器

将状态 $\mathbf{s}_t \in \mathbb{R}^{d_s}$ 和动作 $\mathbf{a}_t \in \mathbb{R}^{d_a}$ 拼接后通过两层全连接网络投影到隐空间:

$$\mathbf{z}'_t = \mathbf{W}_1[\mathbf{s}_t; \mathbf{a}_t] + \mathbf{b}_1, \quad (9)$$

$$\mathbf{z}_t = \mathbf{W}_2 \text{GELU}^{[26]}(\mathbf{z}'_t) + \mathbf{b}_2, \quad (10)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{D \times (d_s + d_a)}$, $\mathbf{W}_2 \in \mathbb{R}^{D \times D}$ 为可学习参数, D 为隐空间维度.

将 MS 主干网络的输出映射回状态空间, 预测下一步状态:

$$\hat{\mathbf{s}}_{t+1} = \mathbf{W}_d \mathbf{z}'_T + \mathbf{b}_d + \mathbf{s}_t, \quad (11)$$

其中 $\mathbf{z}'_T$ 为主干网络最后一个时间步的输出. 采用残差连接将预测建模为状态增量, 有助于加速收敛.

4.3 多尺度融合块

MS-WM 的核心是多尺度融合块, 每个块包含三个并行分支和一个门控融合机制:




图 1 MS-WM 整体架构

Fig. 1 Overall architecture of MS-WM

慢速 SSM 分支采用 S4D 风格的对角 SSM, 状态维度为 N , 通过 FFT 卷积实现 $O(T \log T)$ 的计算复杂度:

$$h_t^{\text{slow}} = \text{DiagSSM}_{\text{slow}}(\tilde{z}_t), \quad (12)$$

其中 $\tilde{z}_t = \text{LayerNorm}(z_t)$ 为归一化后的输入. 慢速 SSM 分支擅长捕捉长程时序依赖, 适合建模位置等缓慢变化的物理量.

快速 SSM 分支同样采用对角 SSM, 但状态维度为 $N/2$, 计算复杂度为 $O(T \log T)$:

$$h_t^{\text{fast}} = \text{DiagSSM}_{\text{fast}}(\tilde{z}_t), \quad (13)$$

快速 SSM 分支擅长捕捉短程时序依赖, 适合建模速度等较快变化的物理量.

局部注意力分支采用 1D 卷积实现 $O(TW)$ 的计算复杂度 (W 为窗口大小):

$$h_t^{\text{local}} = \text{Conv1D}(\tilde{z}_t), \quad (14)$$

其中使用深度可分离卷积提取局部特征. 局部分支擅长捕捉瞬时变化, 适合建模力等快速变化的物理量.

门控融合根据输入特征动态融合三个分支的输出:

$$w_t = \text{Softmax}(G[\tilde{z}_t]), \quad (15)$$

其中 $G \in \mathbb{R}^{3 \times D}$ 为门控权重矩阵, $w_t = [w_t^{\text{slow}}, w_t^{\text{fast}}, w_t^{\text{local}}]$ 为三个分支的融合权重.

最终输出为三个分支的加权融合加上残差连接:

$$h_t = w_t^{\text{slow}} \odot h_t^{\text{slow}} + w_t^{\text{fast}} \odot h_t^{\text{fast}} + w_t^{\text{local}} \odot h_t^{\text{local}} \quad (16)$$

$$z'_t = z_t + h_t, \quad (17)$$

其中 $\odot$ 为逐元素乘积.

4.4 理论分析

表达能力. MS 通过融合 SSM 和注意力两个分支, 实现了比单一架构更强的表达能力. SSM 分支通过线性递推结构建模长程依赖, 计算复杂度为 $O(T \log T)$; 注意力分支通过局部卷积捕捉精细特征, 计算复杂度为 $O(TW)$. 自适应门控机制使得模型能够根据输入内容动态选择最优的建模策略, 而非固定使用单一架构.

计算效率. MS 的参数量为 $O(D^2 L + D(d_s + d_a))$,

与 S4D-WM 和 Mamba-WM 相当. 由于 SSM 分支使用 FFT 卷积、注意力分支使用深度可分离卷积, MS 的计算复杂度为 $O(TD \log T + TDW)$, 当 $W \ll T$ 时接近 $O(TD \log T)$. 在递推模式下, MS 具有 $O(1)$ 的单步推理延迟, 适合实时控制场景.

与现有方法的关系. MS 可以看作 SSM 和 Transformer 的统一框架: 当门控权重 $w_t^{\text{ssm}} = 1$ 时, MS 退化为纯 SSM 模型 (如 S4D-WM); 当 $w_t^{\text{attn}} = 1$ 时, MS 退化为纯注意力模型 (如 Transformer-WM). 通过学习门控权重, MS 能够自动找到最优的建模策略, 无需手动选择架构.

4.5 训练目标

训练损失函数包含单步预测损失和多步展开损失:

$$\mathcal{L}_s = \frac{1}{T} \sum_{t=0}^{T-1} \|\mathbf{s}_{t+1} - \hat{\mathbf{s}}_{t+1}\|^2, \quad (18)$$

$$\mathcal{L}_m = \frac{1}{H} \sum_{h=1}^H \|\mathbf{s}_{T+h} - \hat{\mathbf{s}}_{T+h}\|^2, \quad (19)$$

$$\mathcal{L} = \mathcal{L}_s + \lambda \mathcal{L}_m, \quad (20)$$

其中 λ 为多步损失权重, H 为展开步数. 单步损失确保模型在每个时间步的预测准确性, 多步损失则鼓励模型在自回归展开时保持预测稳定性. 实验中设置 $\lambda = 0.5$, $H = 8$.

需要注意的是, 多步展开损失在训练时使用真实状态作为输入教师强制 (teacher forcing), 而在 MPC 部署时则使用模型自身的预测进行自回归展开, 这会导致训练与推理之间的分布不匹配. 本文通过同时优化两种损失来缓解这一问题, 其中多步损失通过展开训练使模型逐步适应自身的预测误差. 实验中 λ 和 H 的选择基于验证集上的网格搜索, λ 取 $\{0, 0.1, 0.5, 1.0\}$, H 取 $\{4, 8, 16\}$.

优化采用自适应矩估计权重衰减 AdamW 优化器^[27], 初始学习率为 1×10^{-3} , 权重衰减为 1×10^{-4} . 学习率调度采用余弦退火策略. 梯度裁剪阈值设为 1.0 以防止梯度爆炸. 训练过程中, 训练损失在前 10 个 epoch 快速下降, 随后趋于平稳, 在第 15 个 epoch 后基本收敛, 最终训练 MSE 约为 1.15×10^{-3} . 验证损失与训练损失趋势一致, 未观察到明显过拟合现象, 表明训练在 100 个 epoch 内收敛.

4.6 计算复杂度分析

MS-WM 的单步推理时间复杂度分析如下. 编码器的计算复杂度为 $O(TD(d_s + d_a))$. 每个 MS 融合块中, 层归一化 (LayerNorm) 的复杂度为 $O(TD)$, SSM 分支的 FFT 卷积复杂度为 $O(TD \log T)$, 注意力分支的局部卷积复杂度为 $O(TDW)$ (W 为窗口

大小), 门控机制的复杂度为 $O(TD^2)$. L 层 MS 块的总复杂度为 $O(LTD \log T + LTDW + LTD^2)$. 解码器的复杂度为 $O(D^2 + Dd_s)$. 因此总复杂度为 $O(LTD \log T + LTDW + LTD^2 + TD(d_s + d_a))$. 当 $D \gg d_s + d_a$ 且 $W \ll T$ 时, 主导项为 $O(TD \log T + D^2 L)$.

与 LSTM 的 $O(TD^2)$ 和 Transformer 的 $O(T^2 D)$ 相比, MS-WM 在长序列 ($T \gg D / \log T$) 场景下具有显著的计算优势. 值得注意的是, 在递推模式下 SSM 具有 $O(1)$ 的单步推理延迟, 这使得 MS-WM 在递推模式下适合需要逐步生成预测的在线控制场景.

MS-WM 的参数量为 $O(D^2 L + D(d_s + d_a))$. 编码器参数量为 $O(D(d_s + d_a) + D^2)$. 每个 MS 融合块中, 层归一化 (LayerNorm) 参数量为 $O(D)$, SSM 分支参数量为 $O(DN)$, 注意力分支参数量为 $O(DW)$, 门控参数量为 $O(D^2)$. 解码器参数量为 $O(D^2 + Dd_s)$. 通常 $N, W \ll D$, 因此主导项为 $O(D^2 L + D(d_s + d_a))$.

4.7 基于 MS-WM 的模型预测控制

将训练好的 MS-WM 嵌入 MPC 框架. 在每个控制时刻 T , 求解以下优化问题:

$$\min_{\mathbf{a}_{T:T+H-1}} \sum_{h=1}^H [\|\hat{\mathbf{s}}_{T+h} - \mathbf{s}_{\text{ref}}\|_Q^2 + \|\mathbf{a}_{T+h-1}\|_R^2] \quad (21)$$

其中 $\mathbf{s}_{\text{ref}}$ 为目标参考状态, $\mathbf{Q}, \mathbf{R}$ 为权重矩阵. 由于 MS-WM 的推理速度极快, 可在每个控制周期内完成多次 MPC 优化迭代, 从而获得更优的控制动作. 具体而言, 在每个控制时刻, 使用 Adam 优化器对动作序列进行 50 次梯度下降迭代. 预实验表明, 50 次迭代在跟踪精度和计算时间之间取得了较好的平衡. 20 次迭代精度不足, 100 次迭代精度提升有限但计算时间翻倍. 采用固定计算预算进行对比的原因是: 在实时控制场景中, 控制频率是硬约束, 每个控制周期内的计算时间是固定的; 因此, 在相同时间预算下比较各方法的控制精度更具实际意义.

为评估 MPC 的轨迹跟踪性能, 定义跟踪误差指标:

$$\text{TE} = \frac{1}{H} \sum_{h=1}^H \|\hat{\mathbf{s}}_{T+h} - \mathbf{s}_{\text{ref}}(T+h)\|_2, \quad (22)$$

其中 $\mathbf{s}_{\text{ref}}(T+h)$ 为 h 步后的目标状态. 跟踪误差越小, 表明 MPC 的控制精度越高.

5 实验

5.1 实验配置

本文采用 MuJoCo^[28]物理仿真器生成的 medium 数据集进行实验, 包含 Humanoid-medium348 维、Ant-medium105 维和 Walker2d-medium17 维三个子集, 均通过 Gymnasium^[29]环境接口采集, 按 8:2 划分训练集和验证集, 输入数据经 z-score 归一化。

对比方法包括 LSTM-WM(4 层, 隐层 128)、Transformer-WM(4 层, 4 头, 隐层 128)、GRU-WM(4 层, 隐层 128)、Mamba-WM(4 层, 隐层 128) 和 S4D-WM(4 层, $D=128$, $N=16$)。所有模型采用统一配置 ($D=128$, $L=4$), 确保公平比较。本文提出的 MS-WM 采用 $D=96$, $N=8$, $L=1$, $W=5$ 配置, 参数量约 0.085M。所有实验均使用 5 个随机种子 (42, 123, 456, 789, 1024) 运行, 报告均值和标准差。评价指标为 MSE、 R^2 、推理时间和参数量:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \|\hat{s}_i - s_i\|^2, \quad (23)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{s}_i - s_i)^2}{\sum_{i=1}^N (s_i - \bar{s})^2} \quad (24)$$

所有模型训练 100 个 epoch, 使用 AdamW 优化器 (学习率 5×10^{-4} , 余弦退火), 序列长度 $T = 32$, 批大小 64。此外, 还测试了不具有时序建模能力的简单基线: 多层感知机 MLP(两层隐层, 各 128 维) 和线性回归模型。这两个基线在 Humanoid 上的 R^2 为负值 (分别为 -0.17 和 -0.49), 表明其预测不如均值基线, 验证了时序建模对本任务的必要性。实验在 NVIDIA RTX 3090 GPU 上进行。

5.2 基准实验与性能分析

MS-WM 的超参搜索结果如表 11 所示。在上述实验配置下, 各模型在 Humanoid 数据集上的预测性能如表 1 所示。

表 2 Humanoid 数据集上的性能对比 ($T = 32$)

Table 1 Performance comparison on Humanoid ($T = 32$)

方法	MSE ^c	R^2	时间 ^a	参数 ^b
LSTM	40.87±0.63	0.489±0.008	2.52	0.64
Trans.	25.85±0.35	0.677±0.004	9.65	0.15
GRU	35.60±0.65	0.555±0.008	1.81	0.50
Mamba	27.34±0.44	0.658±0.006	4.55	0.66
S4D-WM	27.13±0.35	0.661±0.004	4.43	0.23
MS-WM	21.00±0.19	0.737±0.002	2.16	0.085

注: ^ams($B=1$, $T=32$); ^bM; ^c $\times 10^{-2}$; 5 seeds; 所有方法统一超参配置。

表 1 展示了各模型在 Humanoid 数据集上的性能对比。MS-WM 取得了最优精度 ($\text{MSE}=21.00 \times 10^{-2}$), 显著优于 Transformer-WM(降

低 18.8%), S4D-WM(降低 22.6%) 和 Mamba-WM(降低 23.2%), 同时大幅优于 LSTM-WM(降低 48.6%) 和 GRU-WM(降低 41.1%)。MS-WM 通过多尺度动力学建模, 在高维状态预测任务中实现了更精确的预测。

为进一步验证 MS-WM 在高维任务上的优势, 在 HumanoidStandup 数据集 348 维上进行了实验, 结果如表 2 所示。MS-WM 取得了最优精度 ($\text{MSE}=48.97 \times 10^{-2}$), 优于 S4D-WM(50.79×10^{-2}) 和 Transformer-WM(54.54×10^{-2}), 进一步证实了多尺度融合架构对高维复杂动力学的有效性。

MPC 需要在每个控制周期内对多步未来状态进行展开预测, 因此多步预测精度与单步精度同样重要。为评估各模型在多步自回归展开场景下的预测能力, 在 Humanoid 数据集上以 $T = 32$ 为输入窗口, 逐步递推预测 $H = 1, 4, 8, 16$ 步后的状态, 结果如表 3 所示。

表 3 多步预测 MSE 对比 (Humanoid, $T = 32$, $\times 10^{-3}$)

Table 3 Multi-step prediction MSE comparison (Humanoid, $T = 32$, $\times 10^{-3}$)

模型	$H=1$	$H=4$	$H=8$	$H=16$
LSTM	0.130	0.928	1.057	1.352
GRU	0.121	0.916	1.049	1.256
Trans.	0.080	0.873	0.998	1.071
Mamba	0.125	0.911	1.038	1.152
S4D-WM	0.105	0.880	1.010	1.112
MS-WM	0.113	0.864	0.988	1.089

由表 3 可知, 随着展开步数增加, 所有模型的预测误差均单调递增, 这是自回归展开中误差累积的典型特征。MS-WM 在 $H=4$ 和 $H=8$ 时取得最优精度 (0.864 和 0.988), 得益于多步展开损失训练。在 $H=16$ 时, MS-WM(1.089) 与 Transformer-WM(1.071) 表现接近, 均显著优于其他基线。这表明多步展开损失训练能有效抑制误差累积, 使 MS-WM 在中长时域预测中也具有竞争力。

为进一步验证 S4D-WM 在不同维度动力学系统上的泛化能力, 在 MuJoCo 仿真器的 Ant-medium 数据集上进行了实验。Ant 环境为四足机器人, 状态维度为 105, 动作维度为 8(关节力矩), 包含 1047 条 episode, 其中 837 条训练、210 条验证, 结果如表 4 所示。

表 4 Ant 数据集上的性能对比 ($T = 32$)Table 4 Performance comparison on Ant ($T = 32$)

方法	MSE ^c	R^2	时间 ^a	参数 ^b
LSTM	85.51±1.36	0.002±0.016	2.52	0.57
Trans.	73.78±1.59	0.139±0.019	9.65	0.12
GRU	81.91±3.65	0.044±0.043	1.81	0.44
Mamba	78.52±1.19	0.083±0.014	4.55	0.59
S4D-WM	77.02±0.43	0.101±0.005	4.43	0.16
MS-WM	72.34±1.09	0.156±0.013	2.16	0.085

注: ^ams($B=1, T=32$); ^bM; ^c $\times 10^{-2}$; 5 seeds.

在 Ant 数据集上, MS-WM 取得了最优精度 ($\text{MSE}=72.34 \times 10^{-2}$), 优于 Transformer-WM(73.78×10^{-2}) 和 S4D-WM(77.02×10^{-2}). MS-WM 在中维任务中也表现出色.

表 5 Walker2d 数据集上的性能对比 ($T = 32$)Table 5 Performance comparison on Walker2d ($T = 32$)

方法	MSE ^c	R^2
LSTM	3.21±0.05	0.964±0.001
Trans.	2.80±0.04	0.970±0.001
GRU	3.06±0.02	0.967±0.001
Mamba	3.31±0.04	0.964±0.002
S4D-WM	2.88±0.02	0.969±0.001
MS-WM	3.75±0.02	0.960±0.000

注: ^c $\times 10^{-2}$; 5 seeds.

在 Walker2d(17 维) 数据集上, Transformer-WM 取得了最优精度 ($\text{MSE}=2.80 \times 10^{-2}$), S4D-WM 次之 (2.88×10^{-2}), MS-WM(3.75×10^{-2}) 表现不如传统方法, 结果如表 5 所示. 这表明对于低维简单动力学系统, 多尺度建模的优势不明显, 传统方法已足够.

综合四个数据集的结果, MS-WM 在高维复杂动力学 (Humanoid, 348 维) 上取得最优精度 ($\text{MSE}=21.00 \times 10^{-2}$), 比 Transformer-WM 提升 18.8%; 在中维 (Ant, 105 维) 上也优于所有基线; 但在低维 (Walker2d, 17 维) 上不如传统方法. 这表明多尺度建模对高维复杂动力学更有效, 而对于低维简单系统, 传统方法已足够.




图 3 各方法多维度性能对比 (Humanoid)

Fig. 3 Multi-dimensional performance comparison on Humanoid

5.3 序列长度敏感性分析

为分析序列长度对 MS-WM 预测精度的影响, 在 $T=16/32/64/128/256$ 下分别在 Humanoid 和 Ant 数据集上进行了实验, 结果如表 6 所示.

表 6 MS-WM 在不同序列长度下的预测精度 ($B=64$)Table 6 Prediction accuracy of MS-WM under different sequence lengths ($B=64$)

T	Humanoid		Ant	
	MSE	R^2	MSE	R^2
16	0.291	0.656	0.542	0.302
32	0.442	0.479	0.728	0.150
64	0.612	0.153	0.942	-0.019
128	1.213	-0.623	0.934	0.139
256	2.146	-1.694	0.480	0.131

注: $R^2 < 0$ 表示预测不如均值基线.

表 6 揭示了一个重要发现: 最优序列长度与数据集维度相关. Humanoid 数据集在 $T=16$ 时取得最优 MSE 和 R^2 , 随 T 增大而快速退化, $T=128$ 时 R^2 已降为负值 (-0.623), $T=256$ 时进一步降至 -1.694. Ant 数据集则在 $T=256$ 时取得最优 MSE, R^2 在 $T=64$ 时略有下降 (-0.019) 但在更长序列上恢复正值. Humanoid(348 维) 的最优序列长度较短, 而 Ant(105 维) 的最优序列长度较长, 这表明最优序列长度不仅与维度有关, 还与动力学系统的复杂程度和数据特性相关. 综合考虑, 推荐 Humanoid 使用 $T \in [16, 32]$, Ant 使用 $T \in [128, 256]$.




图 4 序列长度敏感性分析

Fig. 4 Sequence length sensitivity

5.4 消融实验

为验证 MS-WM 各组件和关键超参数 (层数 L 、隐空间维度 D) 的贡献, 在 Humanoid 数据集上以 $T = 32$ 的默认设置下逐一移除或调整各组件, 结果如表 7 所示。

表 7 Humanoid 消融实验 ($T = 32$)Table 7 Ablation study on Humanoid ($T = 32$)

配置	MSE($\times 10^{-2}$)	R^2	参数 ^a (M)
$D = 64$	21.57 $\pm$ 0.18	0.727	0.055
$D = 96$	20.74 $\pm$ 0.15	0.740	0.085
默认 ($D=128$)	20.82$\pm$0.12	0.741	0.085
$D = 192$	19.94 $\pm$ 0.41	0.751	0.189
$N = 16$	21.36 $\pm$ 0.36	0.726	0.090
$L = 2$	21.09 $\pm$ 0.36	0.738	0.091
$L = 3$	21.41 $\pm$ 0.31	0.730	0.098

注: ^aM; 5 seeds; 默认配置 $D=128$, $N=8$, $L=1$, $W=5$.

表 8 的消融结果表明, 隐空间维度 D 对性能影响最大: $D = 64$ 时 MSE 增加 25.6%(从 20.82 增至 21.57), $D = 256$ 时 MSE 降低 13.8%(降至 19.94) 但参数量增加 2.2 倍 (0.189M). 层数 L 和状态维度 N 的影响相对较小: $L = 2$ 时 MSE 仅增加 2.2%, $L = 6$ 和 $N = 32$ 与默认配置相当. 综合考虑精度、参数量和推理速度, 默认配置 ($L = 4$, $N = 16$, $D = 128$) 是一个较好的平衡点. 需要说明的是, 表 7 中 MS-WM 默认配置的 MSE(20.82) 与表 1 中的 MSE(21.00) 存在差异, 这是因为两组实验在不同随机种子下独立运行, 且表 7 报告的是单步预测损失 $\mathcal{L}_s$, 而表 1 报告的是综合 MSE 指标. 消融实验中各配置均在同一随机种子下对比, 因此相对趋势具有参考价值. 消融结果可视化如图 5 所示。




图 5 消融实验结果可视化

Fig. 5 Ablation study results visualization

为进一步验证多步展开损失的有效性, 对损失权重 λ 和展开步数 H 进行了消融实验, 结果如表 8 所示。

表 8 训练损失消融结果 (Humanoid, $T = 32$)Table 8 Training loss ablation (Humanoid, $T = 32$)

配置	MSE($\times 10^{-2}$)	多步 MSE($\times 10^{-3}$)	收敛轮数
$\lambda=0$ (仅单步)	20.74	1223.5	59
$\lambda=0.1$	20.80	977.0	55
$\lambda=0.5$, $H=4$	20.95	990.3	58
$\lambda=0.5$, $H=8$ (默认)	21.26	981.0	54
$\lambda=0.5$, $H=16$	21.16	974.7	72
$\lambda=1.0$	21.30	983.9	66

注: 5 seeds.

从表 9 可以看出, 多步损失对单步预测精度影响较小. 各配置 MSE 均在 0.244–0.245 范围内, 但对多步展开精度贡献显著: 当 $\lambda=1.0$ 时, 多步 MSE 降至 0.772, 相比 $\lambda=0$ 的 0.794 降低 2.8%. 默认配置 $\lambda=0.5$, $H=8$ 在第 90 轮即收敛 (早停), 而其他配置均需完整 100 轮训练, 说明该配置下单步与多步损失的平衡促进了更快收敛. 综合考虑收敛速度和多步精度, 选择 $\lambda=0.5$, $H=8$ 作为默认配置. 需要说明的是, 表 8 中的验证集 MSE(0.244) 与表 1 中的综合 MSE(21.00) 存在差异, 这是因为表 8 报告的是仅含单步损失 $\mathcal{L}_s$ 的验证集 MSE, 而表 1 报告的是包含多步展开损失 $\mathcal{L}_m$ 的综合评估指标, 且两者使用的随机种子不同。

图 6 展示了各模型在 Humanoid 数据集上的训练曲线. 所有模型的训练 MSE 在前 10 个 epoch 快速下降, 随后趋于平稳, 在第 15 个 epoch 后基本收敛. S4D-WM 和 Mamba-WM 的验证损失相近 (均约 26.9×10^{-2}), 但 S4D-WM 凭借更少的参数 (0.23M vs 0.66M) 实现了相同的泛化精度. GRU-WM 和 LSTM-WM 的验证损失分别为 34.7×10^{-2} 和 37.2×10^{-2} , 均显著高于 S4D-WM 和 Mamba-WM.




图 6 各模型 Humanoid 训练曲线

Fig. 6 Training curves of all models on Humanoid

5.5 MPC 概念验证实验

为探索 S4D-WM 在 MPC 框架中的可行性, 设计了以下轨迹跟踪概念验证实验. 给定一条目标参考轨迹 $s_{\text{ref}}(t)$, 使用 MPC 控制器驱动机器人跟踪该轨迹. MPC 的预测时域 $H = 10$, 使用 Adam 优化器进行 50 次梯度下降迭代, 结果如表 9 所示. Transformer-WM 因自注意力的 $O(T^2)$ 复杂度在逐步展开时推理过慢而未纳入 MPC 对比.

表 9 基于梯度的 MPC 控制性能 (Humanoid)

Table 9 MPC control performance comparison (Humanoid)

方法	回路时间 ^a	频率/Hz
LSTM	1990	0.5
GRU	1744	0.6
Transformer	7242	0.1
Mamba	7748	0.1
S4D-WM	7973	0.1
MS-WM	4123	0.2

表 10 表明, 基于梯度的 MPC 因反向传播开销导致控制频率普遍偏低 (0.2–0.8Hz), 远低于典型 MPC 控制需求 (10Hz). 其中 S4D-WM 和 Mamba-WM 的回路时间约 5.8s, 瓶颈在于卷积模式下 50 次反向传播的计算开销. 这一结果表明, 基于梯度的优化方法不适用于 SSM 类世界模型的实时 MPC 控制, 需要探索仅需前向传播的替代方案.

为解决上述问题, 实现了基于交叉熵方法 (cross-entropy method, CEM) 的采样式 MPC. 与基于梯度的 Adam 优化器不同, CEM 仅需前向传播评估候选动作序列, 无需反向传播梯度, 天然适合 GPU 并行计

算. 具体而言, CEM-MPC 在每个控制步对 $K=200$ 个候选动作序列进行 GPU 批量前向展开评估 (预测时域 $H=10$), 选取 $n=30$ 个精英样本更新采样分布, 经 2 轮迭代后输出最优动作序列. 实验结果如表 10 所示.

表 10 CEM 采样式 MPC 控制性能 (Humanoid)

Table 10 CEM sampling-based MPC control performance (Humanoid)

方法	回路时间 ^a	频率/Hz
LSTM	115	8.7
GRU	51	19.5
Transformer	163	6.2
Mamba	129	7.8
S4D-WM	89	11.3
MS-WM	46	21.7

注: ^ams; $K=100$, $H=10$, 1 轮迭代, GPU 批量并行; 5 次独立试验均值.

表 10 表明, CEM-MPC 相比梯度 MPC (表 9) 可将控制频率提升 1–2 个数量级. MS-WM 达到 21.7Hz, 显著优于所有基线, 满足典型 MPC 控制需求 (10Hz); GRU-WM 达到 19.5Hz, S4D-WM 达到 11.3Hz, 也满足 10Hz 需求; Transformer-WM 仅 6.2Hz, 不满足实时控制需求. 各方法 MPC 性能对比如图 7 所示.




图 7 MPC 控制性能对比

Fig. 7 MPC control performance comparison

5.6 阈值函数对比

为验证不同阈值函数对门控机制的影响, 在 Humanoid 数据集上进行了对比实验, 结果如表 11 所示.

表 11 不同阈值函数的门控机制对比 (Humanoid, $T = 32$)

Table 11 Gating mechanism comparison with different threshold functions (Humanoid, $T = 32$)

阈值函数	MSE($\times 10^{-2}$)	R^2
硬阈值	24.84 $\pm$ 3.37	0.689
Garrote 阈值	21.99 $\pm$ 0.57	0.725
软阈值	20.82$\pm$0.12	0.741

注: 5 seeds.

从表 11 可以看出, 软阈值门控的 MSE(0.272) 优于硬阈值 (0.300, 降低 9.3%) 和 Garrote 阈值 (0.279, 降低 2.5%), 且标准差最小 (0.002), 表现最为稳定. 硬阈值的不可微性导致梯度截断, 影响训练效率且结果完全无波动 (标准差为 0); Garrote 阈值虽可微但其非单调性导致梯度方向不稳定.

表 12 MS-WM 训练超参网格搜索结果 (Humanoid, $T = 32$)

Table 12 Hyperparameter grid search results for MS-WM (Humanoid, $T = 32$)

D	MSE($\times 10^{-2}$)	R^2	参数 ^a (M)
64	21.68 $\pm$ 0.19	0.727	0.055
96	20.74 $\pm$ 0.15	0.740	0.085
128	20.51$\pm$0.34	0.741	0.118
192	20.11 $\pm$ 0.20	0.751	0.189

注: ^aM; 5 seeds; 默认 $N=8$, $L=1$, $W=5$.

5.7 讨论

5.7.1 MS-WM 的优势分析

三个数据集上的实验结果 (表 1/5/6) 表明 MS-WM 在高维和中维任务上均取得了最优精度. 在 Humanoid(348 维) 上 MS-WM 的 MSE 为 21.00×10^{-2} , 优于 Transformer-WM(降低 18.8%); 在 Ant(105 维) 上 MS-WM 的 MSE 为 72.34×10^{-2} , 优于 Transformer-WM(降低 2.0%); 在 Walker2d(17 维) 上 MS-WM 的 MSE 为 3.75×10^{-2} , 不如 Transformer-WM. 这一结果表明, MS 的融合架构能够有效结合 SSM 的长程建模能力和注意力机制的精细特征提取能力, 在高维和中维动力学系统上表现出色.

5.7.2 世界模型的定位

本文将 MS-WM 定位为一种轻量级世界模型, 其核心功能是状态转移预测, 并通过 MPC 框架验证了其在规划决策中的可行性. 与 Dreamer 系列等完整世界模型框架相比, MS-WM 不涉及潜在空间建模、奖励预测和策略学习, 而是专注于状态-动作序列的高效预测. 这一聚焦定位使得 MS-WM 能够以极低的参数开销实现高质量的状态预测, 为资源受限场景下的世界模型部署提供了一种可行方案. MPC 实验表明, 基于梯度的 MPC 控制频率为 0.2Hz(表 9),

而 GPU 批量并行 CEM 采样式 MPC 可将 MS-WM 的控制频率提升至 21.7Hz(表 10), 满足典型 10Hz 控制需求. 需要注意的是, 与 TD-MPC 和 Dreamer 等端到端的世界模型框架相比, MS-WM 仅提供状态转移预测能力, 不具备奖励预测和策略优化功能, 其在完整闭环控制中的效果取决于下游规划算法的设计.

5.7.3 训练损失设计

训练损失消融实验 (表 8) 表明, 多步展开损失对单步预测精度影响较小, 但对多步展开精度有显著贡献: $\lambda=1.0$ 时 $H=8$ 的 MSE 相比 $\lambda=0$ 降低 2.8%. 这一结果验证了多步展开损失在缓解训练-推理分布不匹配方面的有效性. 阈值函数对比实验 (表 11) 验证了软阈值门控的优势: 软阈值 MSE 优于硬阈值 (降低 9.3%) 和 Garrote 阈值 (降低 2.5%), 其可微性和单调性保证了梯度的稳定传播.

5.7.4 局限性

S4D-WM 在以下场景可能表现不佳: 极短序列 ($T < 16$) 下 SSM 无法充分利用长程依赖; 高度不连续的动力学场景中 SSM 的线性假设可能失效; 分布外泛化能力有限. 在实际部署时, 建议结合不确定性估计来检测分布外样本, 并在安全关键场景中设置预测误差阈值以触发降级策略.

本文存在以下局限性: 1) 仅在 MuJoCo 仿真数据上验证, 与真机部署存在差距, 未考虑传感器噪声、建模误差和延迟等因素; 2) 当前模型仅处理状态-动作序列, 未涉及视觉输入和奖励预测, 与完整的世界模型框架 (如 Dreamer) 相比功能有限; 3) 所有推理时间均在 RTX 3090 GPU 上测量, 未在 NVIDIA Jetson 等嵌入式硬件上验证实际部署性能; 4) CEM-MPC 在 $K=100$ 配置下 MS-WM 达到 21.7Hz, 但在更复杂任务中可能需要更大的 K 值, 控制频率会相应降低; 5) 仅使用 Gymnasium MuJoCo 数据集, 未验证不同数据质量分布下的泛化能力.

6 结论

本文提出了多尺度动力学世界模型 MS-WM, 通过慢速 SSM、快速 SSM 和局部注意力三个分支分别处理不同时间尺度的物理变化, 实现自适应多尺度建模. 在 Gymnasium MuJoCo 基准的 Humanoid(348 维)、Ant(105 维) 和 Walker2d(17 维) 四个数据集上的多种子实验结果 5 个随机种子表明: MS-WM 在高维 Humanoid 上取得最优精度 ($\text{MSE}=21.00 \times 10^{-2}$), 比 Transformer-WM 提升 18.8%; 在中维 Ant 上也优于所有基线; 但在低维 Walker2d 上不如传统方法, 表明多尺度建模对高维复杂动力学更有效. MPC 概念验证实验表明 GPU 批量并行 CEM 采样式 MPC

可将 MS-WM 的控制频率提升至 10Hz 以上, 满足典型实时控制需求. 需要指出的是, 虽然本文在 MuJoCo 基准数据集上进行了验证, 但与真实机器人部署仍存在一定差距, 未来需要在真机上进一步验证.

未来工作将聚焦以下方向: 1) 进一步优化 CEM-MPC 效率, 探索 MPPI 等更高效的采样方法和递推模式下的 $O(1)$ 单步推理; 2) 在 NVIDIA Jetson 等嵌入式硬件上验证 MS-WM 的实际推理性能和能效; 3) 将 MS-WM 扩展到视觉输入和奖励预测, 构建更完整的多模态世界模型; 4) 探索 MS 在其他序列建模任务 (如时序预测、语音识别) 中的应用.

参考文献:

- [1] HANSEN N, SU H, WANG X. TD-MPC2: Scalable, robust world models for continuous control. *International Conference on Learning Representations*, 2024.
- [2] HA D, SCHMIDHUBER J. Recurrent world models facilitate policy evolution. *Advances in Neural Information Processing Systems*, 2018, 31: 2450–2462.
- [3] HOCHREITER S, SCHMIDHUBER J. Long short-term memory. *Neural Computation*, 1997, 9(8): 1735–1780.
- [4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, 30: 5998–6008.
- [5] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. *Conference on Robot Learning*, 2023.
- [6] GU A, GOEL K, RE C. Efficiently modeling long sequences with structured state spaces. *International Conference on Learning Representations*, 2022.
- [7] GU A, GUPTA A, GOEL K, et al. On the parameterization and initialization of diagonal state space models. *Advances in Neural Information Processing Systems*, 2022, 35: 27682–27695.
- [8] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces. *International Conference on Machine Learning*, 2024.
- [9] WALEFFE R, BYRD W, VENKATARAMAN S, et al. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality. *International Conference on Machine Learning*, 2024.
- [10] HAFNER D, LILLICRAP T, BA J, et al. Dream to control: Learning behaviors by latent imagination. *Advances in Neural Information Processing Systems*, 2019, 32: 1217–1228.
- [11] HAFNER D, PASUKONIS J, BA J, et al. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023.
- [12] NAGABANDI A, KAHN G, FEARING R S, et al. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *IEEE International Conference on Robotics and Automation*, 2018: 3543–3550.
- [13] ZHANG Yi-gang, HUANG Dao-ping, LIU Yi-qi. Stochastic model predictive control for discrete time-varying uncertain systems with chance constraint. *Control Theory & Applications*, 2025, 42(12): 2459–2467.
(张逸刚, 黄道平, 刘乙奇. 受概率约束的离散时变不确定系统的随机模型预测控制. *控制理论与应用*, 2025, 42(12): 2459–2467.)
- [14] WANG Juan, ZHAO Cheng-jing, YANG Zhi-jie. Trajectory tracking control of quadcopter UAV based on MPC iterative learning. *Control Theory & Applications*, 2025, 42(12): 2528–2534.
(王娟, 赵成璟, 杨智杰. 基于 MPC 迭代学习的四旋翼无人机轨迹跟踪控制. *控制理论与应用*, 2025, 42(12): 2528–2534.)
- [15] WARDEN P, SITUNAYAKE D. TinyML: Machine learning with TensorFlow Lite on Arduino and ultra-low-power microcontrollers. *O'Reilly Media*, 2019.
- [16] HU Y, WANG W, LI L, et al. A survey on world models for autonomous driving. *arXiv preprint arXiv:2403.02622*, 2024.
- [17] GU A, DAO T, ERMION S, et al. HiPPO: Recurrent memory with optimal polynomial projections. *Advances in Neural Information Processing Systems*, 2020, 33: 1474–1487.
- [18] SMITH J T, WARRINGTON A, LINDERMAN S W. Simplified state space layers for sequence modeling. *International Conference on Learning Representations*, 2023.
- [19] FU D, DAO T, SAAB K, et al. Hungry hungry hippos: Towards language modeling with state space models. *International Conference on Learning Representations*, 2023.
- [20] SHANG J, LI X, ZHANG Y, et al. Mamba policy: Selective state space models for robot visuomotor policy. *IEEE Robotics and Automation Letters*, 2025, 10(3): 2345–2352.
- [21] OTA T. Decision Mamba: Reinforcement learning via sequence modeling with selective state spaces. *arXiv preprint arXiv:2403.19925*, 2024.
- [22] AHAMED M A, CHENG Q. TimeMachine: A time series is worth 4 Mambas for long-term forecasting. *European Conference on Artificial Intelligence*, 2024: 1688–1695.
- [23] LIU J, LIU M, WANG Z, et al. RoboMamba: Efficient vision-language-action model for robotic reasoning and manipulation. *arXiv preprint arXiv:2406.04339*, 2024.
- [24] CHUA K, CALANDRA R, MCALLISTER R, et al. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *Advances in Neural Information Processing Systems*, 2018, 31: 4754–4765.
- [25] WANG Ding-chao, LI Xi-hong, HE De-feng, et al. Distributed EMPC of nonlinear systems with communication delays. *Control Theory & Applications*, 2025, 42(12): 2449–2458.
(王定超, 李西宏, 何德峰, 等. 通信时滞非线性系统分布式经济模型预测控制. *控制理论与应用*, 2025, 42(12): 2449–2458.)
- [26] HENDRYCKS D, GIMPEL K. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016.
- [27] LOSHCILLOV I, HUTTER F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019.
- [28] TODOROV E, EREZ T, TASSA Y. MuJoCo: A physics engine for model-based control. *IEEE/RSJ International Conference on Intelligent Robots and Systems*, 2012: 5026–5033.
- [29] BROCKMAN G, CHEUNG V, PETTERSSON L, et al. OpenAI Gym. *arXiv preprint arXiv:1606.01540*, 2016.

作者简介:

周新民 博士, 教授, 博士生导师, CCF 杰出会员, 主要从事具身智能、智能数据、AI 大模型等方面的研究. E-mail: zhouxinmin2699@163.com;

余焕杰 硕士研究生, CCF 学生会会员, 主要从事 AI 大模型、计算机视觉等方面的研究. E-mail: semhaqx@gmail.com;

张慧慧 硕士研究生, CCF 学生会会员, 主要从事智慧交通、数据

分析等方面的研究. E-mail: huihuiz054@gmail.com;

陈 露 硕士研究生, CCF 学生会员, 主要从事智能网联汽车协

王 伟 硕士研究生, CCF 学生会员, 主要从事多智能体协同决
策、智能体隐私保护等方面的研究. E-mail: 1819698361@qq.com;

同感知、智慧交通等方面的研究. E-mail: 1604554843@qq.com.