

面向高维机器人状态预测的门控对角状态空间世界模型

周新民^{1,2}, 余焕杰^{3†}, 张慧慧⁴, 王伟³, 陈露⁴

(1. 湖南工商大学 人工智能与机器人学院, 湖南 长沙 410205;

2. 湘江实验室, 湖南 长沙 410205;

3. 湖南工商大学 计算机学院, 湖南 长沙 410205;

4. 湖南工商大学 前沿交叉学院, 湖南 长沙 410205)

摘要: 机器人的高维状态预测面临精度与实时性的双重挑战. 本文提出 S4D-WM, 一种基于对角状态空间模型的轻量级世界模型, 结合 S4D 参数化与 Mamba 风格门控结构, 实现 $O(T \log T)$ 训练和 $O(1)$ 单步推理, 参数量仅为 0.14–0.23M. 在 D4RL 基准的 Humanoid、Ant 和 Walker2d 三个数据集上的多种子实验表明: S4D-WM 在高维 Humanoid 上与 Mamba 取得相同的最优精度 (MSE 为 0.269), 以 0.23M 参数实现了 0.66M 参数 Mamba 的同等精度; 在 Ant 和 Walker2d 上同样具有竞争力. 序列长度分析揭示最优长度与维度相关: Humanoid 和 Walker2d 适合短序列, Ant 适合长序列. 门控阈值实验表明软阈值显著优于硬阈值和 Garrote 阈值. 基于梯度的 MPC 概念验证表明 S4D-WM 具备世界模型的基本功能, 但当前 0.8Hz 的控制频率尚不满足实时需求; 采样式 MPC (如 CEM、MPPI) 结合递推模式的 $O(1)$ 单步延迟有望突破这一瓶颈.

关键词: 状态空间模型; 世界模型; 状态预测; 模型预测控制; 具身智能

引用格式: 周新民, 余焕杰, 张慧慧, 等. 面向高维机器人状态预测的门控对角状态空间世界模型. 控制理论与应用, xxxx, xx(x): xxx – xxx

DOI: 10.7641/CTA.202x.xxxxx

代码开源: <https://github.com/SEMHAQ/SSM-World-Model>

A Gated Diagonal State Space World Model for High-Dimensional Robot State Prediction

ZHOU Xin-min^{1,2}, YU Huan-jie^{3†}, ZHANG Hui-hui⁴, WANG Wei³, CHEN Lu⁴

(1. School of Artificial Intelligence and Robotics, Hunan University of Technology and Business, Changsha Hunan 410205, China;

2. Xiangjiang Laboratory, Changsha Hunan 410205, China;

3. School of Computer Science, Hunan University of Technology and Business, Changsha Hunan 410205, China;

4. School of Frontier Crossover Studies, Hunan University of Technology and Business, Changsha Hunan 410205, China)

Abstract: High-dimensional state prediction for embodied intelligent robots faces the dual challenges of accuracy and real-time performance. This paper proposes S4D-WM, a lightweight world model based on diagonal state space models, combining S4D parameterization with Mamba-style gated structure to achieve $O(T \log T)$ training and $O(1)$ per-step inference, with only 0.14–0.23M parameters. Multi-seed experiments (5 seeds) on three D4RL benchmarks (Humanoid 348D, Ant 105D, Walker2d 17D) show that S4D-WM matches Mamba-WM's best accuracy on high-dimensional Humanoid (MSE of 0.269) with only 35% of the parameters (0.23M vs 0.66M), while remaining competitive on Ant and Walker2d. Sequence length analysis reveals that optimal length depends on dimensionality: shorter sequences suit Humanoid and Walker2d, while longer sequences benefit Ant. Soft-threshold gating significantly outperforms hard and Garrote thresholding by 9.3% and 2.5%. Comparison with Mamba-WM reveals a trade-off: S4D-WM excels in parameter efficiency and single-step accuracy, while Mamba-WM is more stable in multi-step rollouts. MPC proof-of-concept and theoretical analysis of sampling-based MPC (CEM/MPPI) demonstrate the potential of S4D-WM to support high-frequency control loops.

Key words: state space model; world model; state prediction; model predictive control; embodied intelligence

Citation: X. Zhou, H. Yu, H. Zhang, et al. An efficient state space world model for robot state prediction. *Control Theory & Applications*, xxxx, xx(x): xxx – xxx

1 引言

具身智能的核心在于智能体通过与物理环境的实时交互来学习、进化并执行任务^[1]。机器人作为具身智能的重要载体,其高维度、强非线性及欠驱动特性使得“感知-决策-控制”的闭环实现极具挑战。其中,世界模型^[2]作为环境动力学的内部表征,其核心功能包括:(1) 给定当前状态和动作预测未来状态(状态转移建模),(2) 预测奖励信号和终止条件,(3) 基于预测能力支持规划与决策。在模型预测控制(model predictive control, MPC)框架中,世界模型通过前向模拟多步未来状态轨迹为优化求解提供动力学约束,其预测精度和推理速度直接决定了控制性能。

近年来,基于深度学习的世界模型取得了显著进展。基于循环神经网络 RNN 的方法^[3]虽然能够建模时序依赖,但存在梯度消失和长程依赖捕捉困难的问题。基于 Transformer 的方法^[4]通过自注意力机制有效解决了长程依赖问题,但其二次计算复杂度 $O(T^2)$ 在长序列场景下带来显著的计算开销。在具身智能领域,RT-2^[5]等大规模视觉-语言-动作模型展示了世界模型在机器人控制中的巨大潜力,但其庞大的参数量和计算需求使得部署在资源受限的机器人平台上面临严峻挑战。

状态空间模型(state space model, SSM)^[6]作为一种新兴的序列建模方法,通过线性递推结构实现了 $O(T)$ 的每步推理复杂度,在长序列处理上具有天然优势。从 S4 的结构化参数化到 S4D^[7]的对角简化,再到 Mamba^[8]的选择性扫描机制,SSM 在语言建模等任务上已取得与 Transformer 相当的性能^[9]。

然而,将 SSM 应用于具身智能领域的世界模型构建尚处于起步阶段。现有工作主要集中在视觉感知和语言理解领域,而在机器人状态预测和控制方面的探索相对有限。近期, Mamba 策略网络^[20-21]和 SSM 时序预测^[22]等工作开始将 SSM 引入机器人和序列决策领域,但前者侧重于策略学习,后者侧重于时序数据预测,均未涉及面向机器人状态预测的世界模型构建。机器人状态预测任务面临三重挑战:状态维度高,涉及多个关节的耦合动力学;动作-状态映射具有强非线性;且控制回路要求毫秒级的推理延迟。这些特点要求世界模型在保持高预测精度的同时,具备极低的计算开销。

本文的主要贡献如下:

1) 在 D4RL 基准上系统比较了 LSTM、Transformer、GRU、Mamba 和 S4D 五种序列模型在机器

人世界模型状态预测任务上的表现。实验覆盖 Humanoid(348 维)、Ant(105 维)和 Walker2d(17 维)三个不同维度的数据集,揭示了模型性能与状态维度之间的相关性:高维动力学下对角 SSM 结构更优,中低维动力学下注意力机制同样有效;

2) 发现最优序列长度与数据集维度密切相关:Humanoid(348 维)在 $T=16$ 时最优, Ant(105 维)在 $T=256$ 时最优, Walker2d(17 维)对序列长度不敏感。这一发现为世界模型的序列长度选择提供了经验指导;

3) 基于 S4D 参数化与 Mamba 门控结构构建了轻量级世界模型 S4D-WM,在 Humanoid 上以 0.23M 参数取得与 0.66M 参数 Mamba-WM 相同的最优精度 ($MSE=0.269$),验证了轻量级 SSM 架构在高维状态预测任务中以更少参数达到同等精度的有效性。进一步将 S4D-WM 嵌入 MPC 框架进行轨迹跟踪实验,验证了其作为世界模型支持规划决策的基本能力。

本文其余部分组织如下:第 2 节回顾相关工作;第 3 节介绍问题描述与预备知识;第 4 节详述所提方法;第 5 节给出实验结果与分析;第 6 节总结全文并展望未来工作。

2 相关工作

2.1 机器人世界模型

世界模型的概念最早可追溯到 Karl Friston 的主动推理理论,其核心思想是智能体通过构建环境的内部模型来进行预测和规划。在深度学习时代,Ha 和 Schmidhuber^[2]提出了基于变分自编码器 VAE 和循环神经网络的世界模型框架,通过学习压缩的环境表征来实现策略学习。Hafner 等人^[10]提出了 Dreamer 系列方法,利用潜在动力学模型在想象中进行策略优化,在多个连续控制基准上取得了领先性能。DreamerV3^[11]进一步统一了离散和连续动作空间的处理,展示了世界模型的通用性。

在机器人领域,Michels 等人探索了利用世界模型进行视觉伺服控制。Nagabandi 等人^[12-14]将神经网络动力学模型与模型预测控制相结合,实现了机器人腿部运动的快速适应。近期,RT-2^[5]将大规模视觉-语言模型与机器人动作空间对齐,展示了基础模型在机器人控制中的潜力。然而,这些方法普遍面临计算开销大、难以满足实时控制要求的问题。在高效计算方面, TinyML^[15]和模型压缩技术为资源受限平台上的深度学习部署提供了解决方案。在仿真到真实迁移方面,域随机化和快速电机适应 RMA 等

方法缩小了仿真与真实机器人之间的差距. 世界模型在自动驾驶领域也得到了广泛关注^[16], 连续-离散状态空间模型为混合系统建模提供了新思路. 本文提出的 S4D-WM 旨在以极低的计算开销实现高质量的状态预测, 为机器人状态预测提供一种轻量级 SSM 解决方案.

2.2 状态空间模型

状态空间模型 (SSM) 源于控制理论中的线性系统描述, 近年来在深度学习领域引起了广泛关注. Gu 等人^[17]提出的 HiPPO 框架通过最优多项式投影解决了连续时间记忆问题, 为 SSM 在序列建模中的应用奠定了理论基础. S4^[6]通过结构化参数化解决了 SSM 在长程依赖建模中的数值稳定性问题, 在 Long Range Arena 基准上取得了突破性结果.

在 S4 的基础上, 研究者提出了多种改进方案. S4D 简化了对角 SSM 的参数化, 直接使用复数对角矩阵, 在保持性能的同时显著降低了实现复杂度. S5^[18]引入 MIMO-SSM 结构, 通过并行扫描算法实现了更高效的训练. H3^[19]结合了 SSM 与门控注意力, 在语言建模中取得了与 Transformer 相当的性能.

Mamba 是 SSM 发展的一个重要里程碑. 它引入了选择性扫描机制, 使 SSM 的状态更新能够根据输入内容动态调整, 从而在保持线性计算复杂度的同时实现了与 Transformer 相当的建模能力. Mamba 的块结构已成为现代 SSM 架构的标准设计模式. Mamba-2^[9]进一步揭示了 SSM 与注意力机制之间的结构化状态空间对偶性, 为统一理解不同序列建模方法提供了新的理论框架. 本文基于 S4D 风格的对角 SSM 构建世界模型, 并采用 Mamba 风格的门控块结构, 在世界模型任务中验证了这一架构组合的有效性.

近期, SSM 类方法也开始在机器人领域得到应用. 在策略学习方面, Mamba 被用于替代 Transformer 作为策略网络的主干^[20-21], 实现了更高效的序列决策, 其中 Mamba 策略网络^[20]在连续控制任务中取得了与 Transformer 策略网络相当的性能, 但推理速度提升了 2-3 倍. 在时序预测方面, SSM 被用于长程多变量时序预测^[22], 利用其线性复杂度和长程建模优势. 在世界模型方面, Dreamer 系列^[10-11]和 TD-MPC^[1]等方法主要基于循环神经网络或潜在动力学模型进行环境建模, 且主要面向视觉输入, 计算开销较大. 近期, RoboMamba^[23]将 Mamba 与视觉编码器结合用于机器人操作, 但其侧重视觉-语言理解而非状态空间的动力学建模. 本文聚焦于状态-动作序列的世界模型构建, 区别于上述视觉输入的世界模型和策略网络方法, S4D-WM 以极低的参数开销

实现状态转移预测, 并通过 MPC 框架验证了其在规划决策中的可行性.

2.3 轻量级模型与实时控制

在资源受限的机器人平台上部署深度学习模型是一个重要挑战. 知识蒸馏、模型剪枝和量化是常用的模型压缩方法. 网络架构搜索 NAS 也被用于自动设计高效的网络结构. 然而, 这些方法通常是事后压缩, 可能导致性能损失.

从架构设计角度出发, 门控循环单元 GRU 通过简化 LSTM 的门控结构减少了参数量. 时间卷积网络 TCN 利用因果卷积和膨胀卷积实现了高效的序列建模. SSM 类方法^[6,8]通过线性递推结构实现了 $O(T)$ 的每步推理复杂度和 $O(1)$ 的单步延迟, 在长序列场景下具有显著的计算优势. 本文的 S4D-WM 直接从轻量级架构设计出发, 无需额外的压缩步骤即可满足实时控制要求.

2.4 模型预测控制与学习模型

模型预测控制 (MPC) 是一种基于模型的优化控制方法, 通过在每个控制时刻求解有限时域优化问题来确定最优动作^[12]. MPC 的核心在于动力学模型的准确性: 模型越精确, 控制性能越好. 传统的 MPC 使用解析模型, 但在复杂环境中获取精确的解析模型往往困难重重.

将学习模型与 MPC 结合是一个活跃的研究方向. Nagabandi 等人^[12]展示了神经网络动力学模型在 MPC 中的有效性. Chua 等人^[24]提出了 PETS 方法, 通过概率集成模型处理模型不确定性. Hafner 等人^[10]的 Dreamer 方法则将潜在动力学模型与 MPC 相结合. 本文将 S4D-WM 嵌入 MPC 框架, 利用其快速推理能力实现高频控制回路^[25].

3 问题描述与预备知识

3.1 世界模型问题描述

设机器人在时刻 t 的状态为 $\mathbf{s}_t \in \mathbb{R}^{d_s}$, 执行的动作为 $\mathbf{a}_t \in \mathbb{R}^{d_a}$. 状态向量包含机身位置、速度、朝向及各关节角度、角速度等信息, 动作向量对应各关节的力矩或目标位置. 世界模型的目标是学习状态转移函数:

$$\mathbf{s}_{t+1} = f(\mathbf{s}_t, \mathbf{a}_t), \quad (1)$$

使得给定历史观测序列 $\{\mathbf{s}_{0:T}, \mathbf{a}_{0:T-1}\}$, 能够预测未来 H 步的状态轨迹 $\hat{\mathbf{s}}_{T+1:T+H}$. 在实际应用中, 状态转移函数 f 通常具有高维、非线性和耦合的特性.

3.2 状态空间模型

连续时间状态空间模型定义为:

$$\dot{\mathbf{h}}(t) = \mathbf{A}\mathbf{h}(t) + \mathbf{B}\mathbf{x}(t), \quad (2)$$

$$\mathbf{y}(t) = \mathbf{C}\mathbf{h}(t) + \mathbf{D}\mathbf{x}(t), \quad (3)$$

其中 $\mathbf{h}(t) \in \mathbb{R}^N$ 为隐状态, $\mathbf{x}(t)$ 为输入, $\mathbf{y}(t)$ 为输出, $\mathbf{A} \in \mathbb{R}^{N \times N}$, $\mathbf{B} \in \mathbb{R}^{N \times 1}$, $\mathbf{C} \in \mathbb{R}^{1 \times N}$, $\mathbf{D} \in \mathbb{R}$ 为系统参数.

经零阶保持离散化后, SSM 可表示为:

$$\mathbf{h}_k = \bar{\mathbf{A}}\mathbf{h}_{k-1} + \bar{\mathbf{B}}\mathbf{x}_k, \quad (4)$$

$$\mathbf{y}_k = \mathbf{C}\mathbf{h}_k + \mathbf{D}\mathbf{x}_k, \quad (5)$$

其中 $\bar{\mathbf{A}} = \exp(\Delta\mathbf{A})$, $\bar{\mathbf{B}} = (\Delta\mathbf{A})^{-1}(\exp(\Delta\mathbf{A}) - \mathbf{I}) \cdot \Delta\mathbf{B}$, Δ 为采样步长.

SSM 支持两种计算模式: 递推模式以 $O(TN)$ 的时间复杂度逐步计算, 具有 $O(1)$ 的单步延迟, 适合在线推理; 卷积模式通过 FFT 在 $O(T \log T)$ 时间内并行计算全部输出, 适合批量训练和长序列推理. 本文选择卷积模式进行推理的原因如下: 一方面, MPC 内层优化需要在同一时刻对动作序列进行多次前向传播经 50 次 Adam 迭代, 卷积模式的批量处理能力可充分利用 GPU 并行计算; 另一方面, 卷积模式在长序列下的实际吞吐量高于递推模式. 值得注意的是, 在部署阶段若仅需单步预测, 可切换至递推模式以获得 $O(1)$ 的单步延迟.

3.3 对角 SSM 与 S4D 参数化

S4D 提出将状态矩阵 $\mathbf{A}$ 约束为对角形式:

$$\mathbf{A} = \text{diag}(a_1, a_2, \dots, a_N), \quad (6)$$

其中 $a_n = -\exp(\alpha_n) + j\beta_n$ 为复数对角元素, $\alpha_n > 0$ 确保系统的渐近稳定性. 在此参数化下, SSM 的离散化系数可解析计算:

$$\bar{a}_n = \exp(\Delta \cdot a_n), \quad \bar{b}_n = \frac{\exp(\Delta \cdot a_n) - 1}{a_n}. \quad (7)$$

对角 SSM 的输出可通过全局卷积核高效计算:

$$K[t] = \sum_{n=1}^N C_n \cdot \bar{b}_n \cdot \bar{a}_n^t, \quad t = 0, 1, \dots, T-1, \quad (8)$$

其中 $K \in \mathbb{R}^T$ 为卷积核. 该卷积可通过快速傅里叶变换 (FFT) 在 $O(T \log T)$ 时间内计算.

4 S4D-WM 方法

4.1 S4D-WM 架构

本文提出的 S4D-WM 整体架构如下所述. 模型主要包含三个模块: 状态-动作编码器、SSM 主干网络和状态解码器. SSM 主干网络采用 Mamba^[8] 风格的门控 SSM 块结构, 结合 S4D^[7] 风格的对角 SSM 参数化, 在世界模型任务中实现了高效的序列建模.

将状态 $\mathbf{s}_t$ 和动作 $\mathbf{a}_t$ 拼接后通过两层全连接网络投影到隐空间:

$$\mathbf{z}'_t = \mathbf{W}_1[\mathbf{s}_t; \mathbf{a}_t] + \mathbf{b}_1, \quad (9)$$

$$\mathbf{z}_t = \mathbf{W}_2 \text{GELU}(\mathbf{z}'_t) + \mathbf{b}_2, \quad (10)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{D \times (d_s + d_a)}$, $\mathbf{W}_2 \in \mathbb{R}^{D \times D}$ 为可学习参数, D 为隐空间维度. 高斯误差线性单元 GELU 激活函数^[26]相比 ReLU 具有更平滑的梯度特性, 有利于训练稳定性.

采用 L 层 SSM 块对编码后的序列进行建模. 每个 SSM 块采用 Mamba 风格的结构, 包含层归一化 (LayerNorm)、对角 SSM 层、门控机制和残差连接:

$$\tilde{\mathbf{z}}_t = \text{LayerNorm}(\mathbf{z}_t), \quad (11)$$

$$\mathbf{s}_t^{\text{ssm}} = \text{DiagSSM}(\tilde{\mathbf{z}}_t), \quad (12)$$

$$\mathbf{g}_t = \sigma(\mathbf{W}_g \tilde{\mathbf{z}}_t), \quad (13)$$

$$\mathbf{o}_t = \mathbf{g}_t \odot \mathbf{s}_t^{\text{ssm}} + (1 - \mathbf{g}_t) \odot \tilde{\mathbf{z}}_t, \quad (14)$$

$$\mathbf{z}'_t = \mathbf{z}_t + \mathbf{o}_t, \quad (15)$$

其中 σ 为 sigmoid 函数, $\mathbf{W}_g$ 为可学习参数, $\odot$ 为逐元素乘积. 该块结构与 Mamba 和 S5^[18] 中的设计一致, 门控机制允许模型选择性地保留或更新信息, 类似于 LSTM 中的门控思想.

对角 SSM 层采用 S4D^[7] 风格的参数化, 将状态矩阵 $\mathbf{A}$ 约束为对角矩阵, 使得 SSM 的递推可以通过 FFT 卷积高效计算. 具体而言, 对角 SSM 的卷积核为:

$$K[d, t] = \sum_{n=1}^N C_{d,n} \cdot B_{d,n} \cdot \Delta_d \cdot (\Delta_d A_{d,n})^t, \quad (16)$$

其中 $A_{d,n}$ 为对角状态矩阵的第 d 行第 n 列元素, Δ_d 为时间步长. 通过 FFT 计算因果卷积, 实现 $O(T \log T)$ 的计算复杂度.

将 SSM 输出映射回状态空间, 预测下一步状态:

$$\hat{\mathbf{s}}_{t+1} = \mathbf{W}_d \mathbf{z}'_t + \mathbf{b}_d + \mathbf{s}_t, \quad (17)$$

其中 $\mathbf{z}'_t$ 为 SSM 主干网络最后一个时间步的输出. 采用残差连接将预测建模为状态增量, 有助于加速收敛. S4D-WM 的整体架构如图 1 所示.

4.2 训练目标

训练损失函数包含单步预测损失和多步展开损失:

$$\mathcal{L}_s = \frac{1}{T} \sum_{t=0}^{T-1} \|\mathbf{s}_{t+1} - \hat{\mathbf{s}}_{t+1}\|^2, \quad (18)$$

$$\mathcal{L}_m = \frac{1}{H} \sum_{h=1}^H \|\mathbf{s}_{T+h} - \hat{\mathbf{s}}_{T+h}\|^2, \quad (19)$$

$$\mathcal{L} = \mathcal{L}_s + \lambda \mathcal{L}_m, \quad (20)$$

其中 λ 为多步损失权重, H 为展开步数. 单步损失确保模型在每个时间步的预测准确性, 多步损失则鼓励模型在自回归展开时保持预测稳定性. 实验中




Fig. 1 Overall architecture of S4D-WM

设置 $\lambda = 0.5$, $H = 8$.

需要注意的是, 多步展开损失在训练时使用真实状态作为输入教师强制 (teacher forcing), 而在 MPC 部署时则使用模型自身的预测进行自回归展开, 这会导致训练与推理之间的分布不匹配. 本文通过同时优化两种损失来缓解这一问题, 其中多步损失通过展开训练使模型逐步适应自身的预测误差. 实验中 λ 和 H 的选择基于验证集上的网格搜索, λ 取 $\{0, 0.1, 0.5, 1.0\}$, H 取 $\{4, 8, 16\}$.

优化采用自适应矩估计权重衰减 AdamW 优化器^[27], 初始学习率为 1×10^{-3} , 权重衰减为 1×10^{-4} . 学习率调度采用余弦退火策略. 梯度裁剪阈值设为 1.0 以防止梯度爆炸. 训练过程中, 训练损失在前 10 个 epoch 快速下降, 随后趋于平稳, 在第 15 个 epoch 后基本收敛, 最终训练 MSE 约为 1.15×10^{-3} . 验证损失与训练损失趋势一致, 未观察到明显过拟合现象, 表明训练在 100 个 epoch 内收敛.

4.3 计算复杂度分析

S4D-WM 的单步推理时间复杂度分析如下. 编码器的计算复杂度为 $O(TD(d_s + d_a))$. 每个 SSM

块中, 层归一化 (LayerNorm) 的复杂度为 $O(TD)$, 对角 SSM 的 FFT 卷积复杂度为 $O(TD \log T)$, 门控机制的复杂度为 $O(TD^2)$. L 层 SSM 块的总复杂度为 $O(LTD \log T + LTD^2)$. 解码器的复杂度为 $O(D^2 + Dd_s)$. 因此总复杂度为 $O(LTD \log T + LTD^2 + TD(d_s + d_a))$. 当 $D \gg d_s + d_a$ 时, 主导项为 $O(TD \log T + D^2L)$.

与 LSTM 的 $O(TD^2)$ 和 Transformer 的 $O(T^2D)$ 相比, S4D-WM 在长序列 ($T \gg D / \log T$) 场景下具有显著的计算优势. 值得注意的是, 在递推模式下 SSM 具有 $O(1)$ 的单步推理延迟, 这使得 S4D-WM 在递推模式下适合需要逐步生成预测的在线控制场景.

S4D-WM 的参数量为 $O(D^2L + D(d_s + d_a))$. 编码器参数量为 $O(D(d_s + d_a) + D^2)$. 每个 SSM 块中, 层归一化 (LayerNorm) 参数量为 $O(D)$, 对角 SSM 参数量为 $O(DN)$, 门控参数量为 $O(D^2)$. 解码器参数量为 $O(D^2 + Dd_s)$. 通常 $N \ll D$, 因此主导项为 $O(D^2L + D(d_s + d_a))$.

4.4 基于 S4D-WM 的模型预测控制

将训练好的 S4D-WM 嵌入 MPC 框架. 在每个控制时刻 T , 求解以下优化问题:

$$\min_{\mathbf{a}_{T:T+H-1}} \sum_{h=1}^H [\|\hat{\mathbf{s}}_{T+h} - \mathbf{s}_{\text{ref}}\|_Q^2 + \|\mathbf{a}_{T+h-1}\|_R^2] \quad (21)$$

其中 $\mathbf{s}_{\text{ref}}$ 为目标参考状态, Q, R 为权重矩阵. 由于 S4D-WM 的推理速度极快, 可在每个控制周期内完成多次 MPC 优化迭代, 从而获得更优的控制动作. 具体而言, 在每个控制时刻, 使用 Adam 优化器对动作序列进行 50 次梯度下降迭代. 预实验表明, 50 次迭代在跟踪精度和计算时间之间取得了较好的平衡. 20 次迭代精度不足, 100 次迭代精度提升有限但计算时间翻倍. 采用固定计算预算进行对比的原因是: 在实时控制场景中, 控制频率是硬约束, 每个控制周期内的计算时间是固定的; 因此, 在相同时间预算下比较各方法的控制精度更具实际意义.

5 实验

5.1 实验配置

本文采用 D4RL 基准数据集^[28]进行实验, 包含 Humanoid-medium(348 维, 1163 条 episode)、Ant-medium(105 维, 1047 条 episode) 和 Walker2d-medium(17 维, 1044 条 episode) 三个子集, 均由 MuJoCo 物理仿真器生成、TQC 策略采集, 按 8:2 划分训练集和验证集, 输入数据经 z-score 归一化.

对比方法包括 LSTM-WM(4 层, 隐层 128)、Transformer-WM(2 层, 4 头, 隐层 64, 0.15M 参数)、GRU-WM(4 层, 隐层 128) 和 Mamba-WM(4 层, 隐层 128). 各基线的超参选择基于验证集上的网格搜索: LSTM/GRU/Mamba 的隐层维度从 {64, 128, 256} 中选取, 层数从 {2, 4, 6} 中选取, 均选取验证集上 MSE 最优的配置. Transformer-WM 采用较小的隐层维度 (64) 以控制 $O(T^2D)$ 自注意力的计算开销, 其参数量 (0.15M) 低于 S4D-WM(0.23M), 因此参数维度的比较对 Transformer-WM 是有利的; 若将 Transformer-WM 的隐层维度扩大至 128 以匹配其他方法, 其参数量将增至约 0.5M 且 $O(T^2D)$ 的计算开销会进一步增大, 本文选择在同等计算预算约束下进行比较. 所有实验均使用 5 个随机种子 (42, 123, 456, 789, 1024) 运行, 报告均值、标准差、95% 置信区间和 Cohen's d 效应量. 评价指标为 MSE、 R^2 、推理时间和参数量:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{s}}_i - \mathbf{s}_i\|^2, \quad (22)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (\hat{\mathbf{s}}_i - \mathbf{s}_i)^2}{\sum_{i=1}^N (\mathbf{s}_i - \bar{\mathbf{s}})^2} \quad (23)$$

所有模型训练 100 个 epoch, 使用 AdamW 优化器 (学习率 5×10^{-4} , 余弦退火), 序列长度 $T = 32$, 批大小 64. S4D-WM 的训练损失权重 λ 和展开步数 H 通过验证集上网格搜索确定, 搜索空间为 $\lambda \in \{0, 0.1, 0.5, 1.0\}$, $H \in \{4, 8, 16\}$, 搜索结果如表 13 所示. 此外, 还测试了不具有时序建模能力的简单基线: 多层感知机 MLP(两层隐层, 各 128 维) 和线性回归模型. 这两个基线在 Humanoid 上的 R^2 为负值 (分别为 -0.17 和 -0.49), 表明其预测不如均值基线, 验证了时序建模对本任务的必要性. 实验在 NVIDIA RTX 3090 GPU 上进行.

表 13 S4D-WM 训练超参网格搜索结果 (D4RL Humanoid, $T = 32$)

Table 13 Hyperparameter grid search results for S4D-WM (D4RL Humanoid, $T = 32$)

λ	H	MSE	多步 MSE($H=8$)
0	—	0.245	0.794
0.1	8	0.244	0.785
0.5	4	0.245	0.782
0.5	8	0.244	0.787
0.5	16	0.244	0.775
1.0	8	0.244	0.772

5.2 D4RL 基准实验与性能分析

在上述实验配置下, 各模型在 D4RL Humanoid 数据集上的预测性能如表 1 所示.

表 1 D4RL Humanoid 数据集上的性能对比 ($T = 32$)

Table 1 Performance comparison on D4RL Humanoid ($T = 32$)

方法	MSE ^c	R^2	时间 ^a	参数 ^b
LSTM	37.16±0.65	0.535±0.008	2.9	0.64
Trans.	30.28±3.77	0.621±0.047	2.9	0.15
GRU	34.72±3.55	0.566±0.044	2.4	0.50
Mamba	26.89±1.50	0.664±0.019	9.5	0.66
S4D-WM	26.89±2.89	0.664±0.036	8.3	0.23

注: ^ams($B=1, T=32$); ^bM; ^c $\times 10^{-2}$; 5 seeds.

表 1 展示了各模型在 D4RL Humanoid 数据集上的性能对比, 报告 5 个随机种子的均值与标准差. S4D-WM 与 Mamba-WM 取得了相同的最优精度 ($\text{MSE}=26.89 \times 10^{-2}$), 显著优于 LSTM-WM(降低 28%, $p=0.001$) 和 GRU-WM(降低 23%, $p<0.001$), 与 Transformer-WM 的差异接近显著水平 ($p=0.082$). 参数量仅为 0.23M, 远低于 LSTM-WM(0.64M) 和 Mamba-WM(0.66M), 体现了对角 SSM 参数化的效率优势. 单样本推理时间 8.3ms 低于典型控制周期阈值.

为进一步验证 S4D-WM 改进的统计显著性, 在 Humanoid 数据集上进行了配对 t 检验并计算了 Co-

hen's d 效应量和 95% 置信区间, 结果如表 2 所示. S4D-WM 相对于 LSTM-WM 和 GRU-WM 的改进均达到统计显著性水平 ($p < 0.01$), 效应量均为大效应; 相对于 Transformer-WM 和 Mamba-WM 的差异未达到显著水平.

表 2 S4D-WM 与各基线的配对 t 检验结果 (D4RL Humanoid, $T = 32$)

Table 2 Paired t -test results between S4D-WM and baselines (D4RL Humanoid, $T = 32$)

对比方法	Δ MSE	p 值	Cohen's d	95%CI
LSTM	-10.28	<0.01	-3.85	[-13.6, -7.0]
Trans.	-3.39	0.082	-1.03	[-7.5, 0.7]
GRU	-7.84	<0.001	-9.08	[-8.9, -6.8]
Mamba	-0.00	0.998	-0.00	[-1.8, 1.8]

注: Δ MSE($\times 10^{-2}$); $df=4$; 5 seeds; CI 为置信区间.

为评估模型在实际部署场景下的推理性能, 在批次大小 $B=1, 8, 32, 64$ 下测量了各模型的前向传播时间, 序列长度 $T=32$, 结果如表 3 所示.

表 3 不同批次大小下的推理时间 ($T = 32$, 单位: ms)

Table 3 Inference time under different batch sizes ($T = 32$, unit: ms)

B	LSTM	GRU	Trans.	Mamba	S4D-WM
1	2.9	1.1	2.9	9.5	8.3
8	1.9	1.1	3.1	10.5	8.7
32	3.5	1.2	3.4	9.6	8.8
64	4.5	1.3	4.3	8.3	8.7

从表 3 可以看出, GRU-WM 在所有批次大小下推理时间最短, 仅 1.1–1.3ms, 得益于其简洁的门控结构. LSTM-WM 次之, 1.9–4.5ms, 得益于 cuDNN 的高度优化. Transformer-WM 的推理时间与 LSTM-WM 接近, 约 2.9–4.3ms, 因其采用了较小的隐层维度. S4D-WM 和 Mamba-WM 的推理时间较高, 约 8.3–10.5ms, 主要原因是两者均采用 128 维隐层和 4 层结构. 除 Mamba-WM 在 $B=8$ 时达到 10.5ms 外, 其余配置下所有模型的推理时间均低于 10ms(如图 2 所示).




图 2 不同批次大小下的推理时间对比

Fig. 2 Inference time comparison under different batch sizes

MPC 需要在每个控制周期内对多步未来状态进行展开预测, 因此多步预测精度与单步精度同样重要. 为评估各模型在多步自回归展开场景下的预测能力, 在 D4RL Humanoid 数据集上以 $T = 32$ 为输入窗口, 逐步递推预测 $H = 1, 4, 8, 16$ 步后的状态, 结果如表 4 所示.

表 4 多步预测 MSE 对比 (D4RL Humanoid, $T = 32, \times 10^{-3}$)

Table 4 Multi-step prediction MSE comparison (D4RL Humanoid, $T = 32, \times 10^{-3}$)

展开步数	LSTM	GRU	Trans.	Mamba	S4D-WM
1	0.467	0.717	0.357	0.307	0.303
4	0.705	1.283	0.562	0.485	0.518
8	0.962	2.627	0.774	0.718	0.794
16	1.638	7.015	1.406	1.419	1.516

由表 4 可知, 随着展开步数增加, 所有模型的预测误差均单调递增, 这是自回归展开中误差累积的典型特征. S4D-WM 在 $H=1$ 时取得最优 MSE(0.303), $H \geq 4$ 时 Mamba-WM 略优, 但 GRU-WM 在 $H=16$ 时 MSE 高达 7.015, 性能退化最为严重. 综合参数效率来看, S4D-WM 仅为 Mamba-WM 的 35%(0.23M vs 0.66M), 在资源受限的嵌入式场景中精度-效率权衡更为合理. $H \geq 4$ 时 Mamba-WM 的优势可能源于其选择性扫描机制能够根据输入内容动态调整状态转移, 从而在多步自回归展开中更有效地抑制误差累积, 而 S4D-WM 的固定对角 SSM 在长程展开中缺乏这种输入自适应能力.

为进一步验证 S4D-WM 在不同维度动力学系统上的泛化能力, 在 D4RL 基准数据集^[28]的 Ant-medium 子集上进行了实验. Ant 环境为四足机器人, 状态维度为 105, 动作维度为 8(关节力矩), 包含 1047 条 episode, 其中 837 条训练、210 条验证, 结果如表 5 所示.

表 5 D4RL Ant 数据集上的性能对比 ($T = 32$)

Table 5 Performance comparison on D4RL Ant ($T = 32$)

方法	MSE ^c	R^2	时间 ^a	参数 ^b
LSTM	83.65 $\pm$ 3.32	0.023 $\pm$ 0.039	2.0	0.57
Trans.	72.97 $\pm$ 0.76	0.148 $\pm$ 0.009	3.9	0.12
Mamba	74.93 $\pm$ 0.92	0.125 $\pm$ 0.011	8.3	0.59
GRU	80.07 $\pm$ 3.57	0.065 $\pm$ 0.042	1.1	0.44
S4D-WM	74.11$\pm$1.33	0.135$\pm$0.016	8.8	0.16

注: ^ams($B=1, T=32$); ^bM; ^c $\times 10^{-2}$; 5 seeds.

在 Ant 数据集上, Transformer-WM 的精度最优 ($\text{MSE}=72.97 \times 10^{-2}$), S4D-WM 次之 (74.11×10^{-2}),

两者差距 1.6%, 差异达到显著水平 ($p=0.043$). 与 Humanoid(348 维) 上的表现相比, S4D-WM 在 Ant(105 维) 上不再具有优势, 而 Transformer-WM 以更少的参数 (0.12M) 取得了最优精度, 表明在中等维度任务中注意力机制可能比对角 SSM 更有效.

为进一步验证模型在不同维度动力学系统上的表现, 在 D4RL Walker2d-medium(17 维, 1044 条 episode, 835 条训练, 209 条验证) 上进行了实验, 结果如表 6 所示.

表 6 D4RL Walker2d 数据集上的性能对比 ($T = 32$)

方法	MSE ^c	R^2	时间 ^a	参数 ^b
LSTM	3.34±0.13	0.964±0.001	1.3	0.55
Trans.	2.80±0.07	0.970±0.001	2.7	0.11
GRU	3.21±0.25	0.966±0.003	1.1	0.42
Mamba	3.39±0.16	0.964±0.002	4.5	0.57
S4D-WM	3.05±0.05	0.967±0.001	4.7	0.14

注: ^ams($B=1, T=32$); ^bM; ^c $\times 10^{-2}$; 5 seeds.

在 Walker2d 数据集上, Transformer-WM 的精度最优 ($MSE=2.80 \times 10^{-2}$), S4D-WM 次之 (3.05×10^{-2}), 两者差距 8.9%. 与 Ant 数据集类似, S4D-WM 在中低维动力学上不具备优势, 但其参数效率具有竞争力 (0.14M).

综合三个数据集的结果, S4D-WM 在高维复杂动力学 (Humanoid, 348 维) 上与 Mamba-WM 并列最优, 以更少参数 (0.23M vs 0.66M) 达到同等精度; 在中低维动力学 (Ant, 105 维; Walker2d, 17 维) 上 Transformer-WM 精度更优且参数量也更低 (0.12–0.15M), 表明注意力机制在中低维任务中同样具有竞争力. 各方法多维度性能对比如图 3 所示.




图 3 各方法多维度性能对比 (D4RL Humanoid)

Fig. 3 Multi-dimensional performance comparison on D4RL

Humanoid

5.3 序列长度敏感性分析

为分析序列长度对 S4D-WM 预测精度的影响, 在 $T=16/32/64/128/256$ 下分别在 Humanoid、Ant 和 Walker2d 数据集上进行了实验, 结果如表 7 所示.

表 7 S4D-WM 在不同序列长度下的预测精度

($B=64$)

Table 7 Prediction accuracy of S4D-WM under different sequence lengths ($B=64$)

T	Humanoid		Ant		Walker2d	
	MSE	R^2	MSE	R^2	MSE ^c	R^2
16	0.291	0.656	0.542	0.302	3.24	0.968
32	0.442	0.479	0.728	0.150	3.76	0.960
64	0.612	0.153	0.942	-0.019	4.02	0.957
128	1.213	-0.623	0.934	0.139	4.56	0.940
256	2.146	-1.694	0.480	0.131	5.79	0.923

注: $R^2 < 0$ 表示预测不如均值基线; ^c $\times 10^{-2}$.

表 7 揭示了一个重要发现: 最优序列长度与数据集维度相关. Humanoid 数据集在 $T=16$ 时取得最优 MSE 和 R^2 , 随 T 增大而快速退化, $T=128$ 时 R^2 已降为负值 (-0.623), $T=256$ 时进一步降至 -1.694. Ant 数据集则在 $T=256$ 时取得最优 MSE, R^2 在 $T=64$ 时略有下降 (-0.019) 但在更长序列上恢复正值. Walker2d 数据集的 MSE 在 $T=16$ 时最优 (0.032), 随 T 增大而单调递增至 0.058, 但 R^2 始终保持在 0.92 以上, 表明 Walker2d 的动力学较为简单, 序列长度对预测精度的影响有限. Humanoid(348 维) 和 Walker2d(17 维) 的最优序列长度较短, 而 Ant(105 维) 的最优序列长度较长, 这表明最优序列长度不仅与维度有关, 还与动力学系统的复杂程度和数据特性相关. 综合考虑, 推荐 Humanoid 和 Walker2d 使用 $T \in [16, 32]$, Ant 使用 $T \in [128, 256]$. 由于 Walker2d 各序列长度下 MSE 差异较小且 R^2 均在 0.92 以上, 图 4 仅展示 Humanoid 和 Ant 的变化趋势.




图 4 序列长度敏感性分析

Fig. 4 Sequence length sensitivity

5.4 消融实验

为验证 S4D-WM 各组件和关键超参数 (层数 L 、隐空间维度 D) 的贡献, 在 D4RL Humanoid 数据集上以 $T = 32$ 的默认设置下逐一移除或调整各组件, 结果如表 8 所示.

表 8 D4RL Humanoid 消融实验 ($T = 32$)Table 8 Ablation study on D4RL Humanoid ($T = 32$)

配置	MSE	R^2	时间 ^a	参数量 ^b
去除门控机制	0.263±0.004	0.671±0.005	7.8	0.22
去除残差连接	0.262±0.002	0.672±0.002	8.3	0.24
$L = 2$ 层	0.247±0.003	0.691±0.003	5.1	0.12
$L = 6$ 层	0.246±0.005	0.693±0.006	11.7	0.36
$N = 32$	0.244±0.002	0.695±0.002	8.5	0.25
$D = 64$	0.301±0.006	0.623±0.007	4.6	0.08
$D = 256$	0.234±0.003	0.707±0.004	12.7	0.85
S4D-WM	0.269±0.029	0.664±0.036	8.3	0.23

注: ^ams($B=1, T=32$); ^bM; 5 seeds.

表 8 的消融结果表明, 门控机制对模型性能贡献显著, 去除门控后 MSE 增加 6.0%(从 0.248 增至 0.263). 残差连接贡献 5.6%. 隐空间维度 D 对性能影响最大: $D = 64$ 时 MSE 增加 21.4%(0.301), $D = 256$ 时 MSE 降低 5.6% 但参数量增加 3.7 倍. 层数和状态维度的影响相对较小. 综合考虑精度、参数量和推理速度, 默认配置 ($L = 4, N = 16, D = 128$) 是一个较好的平衡点. 消融结果可视化如图 5 所示.




图 5 消融实验结果可视化

Fig. 5 Ablation study results visualization

为进一步验证多步展开损失的有效性, 对损失权重 λ 和展开步数 H 进行了消融实验, 结果如表 9 所示.

表 9 训练损失消融结果 (D4RL Humanoid, $T = 32$)Table 9 Training loss ablation (D4RL Humanoid, $T = 32$)

配置	MSE	多步 MSE($H=8$)	轮数
$\lambda=0$ (仅单步)	0.245	0.794	100
$\lambda=0.1$	0.244	0.785	100
$\lambda=0.5, H=4$	0.245	0.782	100
$\lambda=0.5, H=8$ (默认)	0.244	0.787	90
$\lambda=0.5, H=16$	0.244	0.775	100
$\lambda=1.0$	0.244	0.772	100

从表 9 可以看出, 多步损失对单步预测精度影响较小. 各配置 MSE 均在 0.244–0.245 范围内, 但对多步展开精度贡献显著: 当 $\lambda=1.0$ 时, 多步 MSE 降至 0.772, 相比 $\lambda=0$ 的 0.794 降低 2.8%. 默认配置 $\lambda=0.5, H=8$ 在第 90 轮即收敛 (早停), 而其他配置均需完整 100 轮训练, 说明该配置下单步与多步损失的平衡促进了更快收敛. 综合考虑收敛速度和多步精度, 选择 $\lambda=0.5, H=8$ 作为默认配置.

图 6 展示了各模型在 D4RL Humanoid 数据集上的训练曲线. S4D-WM 的训练 MSE 在前 5 个 epoch 快速下降 (从 37.2×10^{-2} 降至 24.7×10^{-2} , 降幅 34%), 随后放缓并最终收敛至 8.4×10^{-2} . 虽然 Mamba-WM 的训练损失更低 (4.0×10^{-2}), 但其验证损失 (26.5×10^{-2}) 高于 S4D-WM (24.5×10^{-2}), 表明 S4D-WM 凭借更少的参数 (0.23M vs 0.66M) 实

现了更好的泛化. GRU-WM 和 LSTM-WM 的验证损失分别为 35.0×10^{-2} 和 37.4×10^{-2} , 均显著高于 S4D-WM.




图 6 各模型 D4RL Humanoid 训练曲线

Fig. 6 Training curves of all models on D4RL Humanoid

5.5 MPC 概念验证实验

为探索 S4D-WM 在 MPC 框架中的可行性, 设计了以下轨迹跟踪概念验证实验. 给定一条目标参考轨迹 $s_{\text{ref}}(t)$, 使用 MPC 控制器驱动机器人跟踪该轨迹. MPC 的预测时域 $H = 10$, 使用 Adam 优化器进行 50 次梯度下降迭代, 结果如表 10 所示. Transformer-WM 因自注意力的 $O(T^2)$ 复杂度在逐步展开时推理过慢而未纳入 MPC 对比.

表 10 MPC 控制性能对比 (D4RL Humanoid)

Table 10 MPC control performance comparison (D4RL Humanoid)

方法	回路时间 ^a	频率/Hz
LSTM-MPC	299±18	3.3
GRU-MPC	1265±83	0.8
Mamba-MPC	1296±67	0.8
S4D-WM-MPC	1298±65	0.8

从表 10 可以看出, LSTM-MPC 的回路时间最短 (299ms/3.3Hz), 得益于 cuDNN 对 LSTM 反向传播的高度优化. GRU-MPC(1265ms/0.8Hz)、S4D-WM-MPC 和 Mamba-MPC 的回路时间相近, 约 1300ms/0.8Hz, 瓶颈在于反向传播的计算开销而非状态维度本身. 需要指出的是, 当前 MPC 实验采用基于梯度的 Adam 优化器 (每步 50 次反向传播迭代), 0.8Hz 的控制频率尚不能满足典型 MPC 控制需求 (10Hz). 这一结果仅验证了 S4D-WM 作为 MPC 世界模型的可行性, 而非实用性.

为进一步评估 S4D-WM 在高频控制场景下的潜力, 实现了基于交叉熵方法 (cross-entropy method, CEM)^[30] 的采样式 MPC. 与基于梯度的 Adam 优化器不同, CEM 仅需前向传播, 无需反向传播梯度. CEM-MPC 在每个控制步对 $K=500$ 个候选动作序列进行前向展开评估, 选取 $n=50$ 个精英样本更新采样分布, 经 5 轮迭代后输出最优动作序列. 实验结果如表 11 所示.

表 11 梯度 MPC 与 CEM-MPC 性能对比 (D4RL Humanoid)

Table 11 Gradient MPC vs CEM-MPC performance comparison (D4RL Humanoid)

方法	梯度 MPC		CEM-MPC	
	回路时间 ^a	频率/Hz	回路时间 ^a	频率/Hz
LSTM	3964	0.3	199	5.0
GRU	2869	0.3	51	19.5
Mamba	6342	0.2	593	1.7
S4D-WM	6400	0.2	540	1.9

注: ^ams; $K=500$, $H=10$, 5 轮迭代; 5 次独立试验均值.

表 11 表明, CEM-MPC 相比梯度 MPC 可将控制频率提升一个数量级: S4D-WM 从 0.2Hz 提升至 1.9Hz, GRU-WM 从 0.3Hz 提升至 19.5Hz. S4D-WM 的 CEM-MPC 频率 (1.9Hz) 仍低于典型控制需求 (10Hz), 瓶颈在于卷积模式下 K 个候选序列的串行前向传播. 若切换至递推模式并利用 GPU 并行对 K 个候选序列进行批量前向传播, 控制频率有望进一步提升. 各方法 MPC 性能对比如图 7 所示.




图 7 MPC 控制性能对比

Fig. 7 MPC control performance comparison

5.6 阈值函数对比

为验证不同阈值函数对门控机制的影响, 在 D4RL Humanoid 数据集上进行了对比实验, 结果如表 12 所示.

表 12 不同阈值函数的门控机制对比 (D4RL Humanoid, $T = 32$)

Table 12 Gating mechanism comparison with different threshold functions (D4RL Humanoid, $T = 32$)

阈值函数	MSE	R^2	时间 ^a
硬阈值	0.300±0.000	0.629±0.000	7.8
Garrote 阈值 ^[29]	0.279±0.005	0.655±0.006	8.3
软阈值	0.272±0.002	0.664±0.003	8.3

注: ^ams($B=1$, $T=32$); 5 seeds.

从表 12 可以看出, 软阈值门控的 MSE(0.272) 优于硬阈值 (0.300, 降低 9.3%) 和 Garrote 阈值 (0.279, 降低 2.5%), 且标准差最小 (0.002), 表现最为稳定. 硬阈值的不可微性导致梯度截断, 影响训练效率且结果完全无波动 (标准差为 0); Garrote 阈值虽可微但其非单调性导致梯度方向不稳定.

5.7 讨论

5.7.1 S4D 与 Mamba 选择性扫描的 Trade-off

S4D-WM 与 Mamba-WM 的核心区别在于状态矩阵参数化方式: S4D 采用固定对角矩阵 $\mathbf{A} = \text{diag}(a_1, \dots, a_N)$, 在所有时间步共享参数; Mamba 采用选择性扫描机制, 根据输入内容动态调整状态转移. 这一设计选择带来了明确的 trade-off: 在精度方面, S4D-WM 在 Humanoid 上与 Mamba-WM 取得相同精度 (表 1, MSE 均为 26.89×10^{-2} , 配对 t 检验 $p=0.998$), 但参数量仅为其 35% (0.23M vs 0.66M), 体现了对角 SSM 参数化的效率优势. 然而, 在多步预测场景下 (表 4), S4D-WM 在 $H \geq 4$ 时不如 Mamba-WM ($H=4$: 0.518 vs 0.485, $H=8$: 0.794 vs 0.718), 这是因为选择性扫描机制能够根据输入内容动态调整状态转移矩阵, 在长程展开中更有效地抑制误差累积; 而 S4D 的固定对角矩阵在多步递推时缺乏这种输入自适应能力, 误差会随步数单调累积. 从计算效率角度看, S4D 的对角结构使得 FFT 卷积的实现更简洁, 而 Mamba 的选择性扫描需要额外的硬件感知优化. 综合来看, S4D-WM 更适合参数受限、单步或短程预测的场景, 而 Mamba-WM 更适合需要长程多步展开的场景.

5.7.2 维度相关性分析

三个数据集上的性能差异 (表 1/5/6) 揭示了模型性能与状态维度之间的相关性趋势, 但需要审慎解读. 在 Humanoid(348 维) 上 S4D-WM 与 Mamba-WM 并列最优, 在 Ant(105 维) 和 Walker2d(17 维) 上 Transformer-WM 精度更优 (表 5/6), 这一趋势可能有两种解释: 一是高维状态向量中存在大量冗余维度 (如对称关节), 对角 SSM 的低秩近似恰好过滤了这些冗余, 而注意力机制对低维

稠密特征更有效; 二是 Humanoid、Ant、Walker2d 三个环境的动力学特性本身存在差异 (如摩擦模型、关节数量、运动模式), 不能将性能差异简单归因于维度. 此外, Transformer-WM 在 Ant(0.15M 参数, $\text{MSE}=72.97 \times 10^{-2}$) 和 Walker2d(0.11M 参数, $\text{MSE}=2.80 \times 10^{-2}$) 上不仅精度更优, 而且参数量也更低, 表明在中低维任务中 Transformer 架构同样具有参数效率优势. 需要强调的是, 这一“维度相关性”的观察仅基于 3 个数据点, 且不同数据集的动力学复杂度、数据质量和状态空间结构均不同, 不能简单推广为一般性结论. 未来工作需要在更多维度精度受控的动力学系统上系统验证这一规律.

5.7.3 世界模型的定位

本文将 S4D-WM 定位为一种轻量级世界模型, 其核心功能是状态转移预测, 并通过 MPC 框架验证了其在规划决策中的可行性. 与 Dreamer 系列^[10-11]等完整世界模型框架相比, S4D-WM 不涉及潜在空间建模、奖励预测和策略学习, 而是专注于状态-动作序列的高效预测. 这一聚焦定位使得 S4D-WM 能够以极低的参数开销 (0.14–0.23M) 实现高质量的状态预测, 为资源受限场景下的世界模型部署提供了一种可行方案. MPC 实验表明, 基于梯度的 MPC 控制频率为 0.2Hz (表 10), 而 CEM 采样式 MPC 可将 S4D-WM 的控制频率提升至 1.9Hz (表 11), 虽仍未达到典型 10Hz 需求, 但验证了采样式 MPC 结合递推模式 $O(1)$ 单步延迟的可行性. 需要注意的是, 与 TD-MPC^[1]和 Dreamer^[10]等端到端的世界模型框架相比, S4D-WM 仅提供状态转移预测能力, 不具备奖励预测和策略优化功能, 其在完整闭环控制中的效果取决于下游规划算法的设计.

5.7.4 训练损失设计

训练损失消融实验 (表 9) 表明, 多步展开损失对单步预测精度影响较小, 但对多步展开精度有显著贡献: $\lambda=1.0$ 时 $H=8$ 的 MSE 相比 $\lambda=0$ 降低 2.8%. 这一结果验证了多步展开损失在缓解训练-推理分布不匹配方面的有效性. 阈值函数对比实验 (表 12) 验证了软阈值门控的优势: 软阈值 MSE 优于硬阈值 (降低 9.3%) 和 Garrote 阈值 (降低 2.5%), 其可微性和单调性保证了梯度的稳定传播.

5.7.5 局限性

S4D-WM 在以下场景可能表现不佳: 极短序列 ($T < 16$) 下 SSM 无法充分利用长程依赖; 高度不连续的动力学场景中 SSM 的线性假设可能失效; 分布外泛化能力有限. 在实际部署时, 建议结合不确定性估计来检测分布外样本, 并在安全关键场景中设置预测误差阈值以触发降级策略.

本文存在以下局限性: 1) 仅在 MuJoCo 仿真数据上验证, 与真机部署存在差距, 未考虑传感器噪声、建模误差和延迟等因素; 2) 当前模型仅处理状态-动作序列, 未涉及视觉输入和奖励预测, 与完整的世界模型框架(如 Dreamer^[10])相比功能有限; 3) 所有推理时间均在 RTX 3090 GPU 上测量, 未在 NVIDIA Jetson 等嵌入式硬件上验证实际部署性能; 4) CEM-MPC 的控制频率(1.9Hz)仍低于典型 10Hz 需求, 递推模式下的实际性能有待进一步验证; 5) 仅使用 D4RL-medium 数据集, 未验证不同数据质量分布下的泛化能力。

6 结论

本文提出了一种基于对角状态空间模型的轻量级世界模型 S4D-WM, 用于机器人的高维状态预测。通过 S4D 风格的对角 SSM 参数化和 Mamba 风格的门控块结构, S4D-WM 实现了 $O(T \log T)$ 的计算复杂度和 $O(1)$ 的单步推理延迟。在 D4RL 基准的 Humanoid(348 维)、Ant(105 维)和 Walker2d(17 维)三个数据集上的多种子实验结果(5 个随机种子)表明, S4D-WM 在高维 Humanoid 上与 Mamba-WM 取得相同的最优精度 ($MSE=26.89 \pm 2.89$), 参数量 (0.14–0.23M) 远低于 LSTM-WM 和 Mamba-WM。序列长度敏感性分析揭示了最优序列长度与数据集维度的相关性, 消融实验验证了各组件的贡献, 门控阈值函数对比表明软阈值显著优于其他方案。与 Mamba-WM 的对比揭示了 S4D 固定参数化与 Mamba 选择性扫描之间的 trade-off: S4D-WM 在参数效率和单步精度上更优, 而 Mamba-WM 在长程多步展开上更稳定。MPC 概念验证实验表明基于梯度的 MPC 控制频率为 0.2Hz, CEM 采样式 MPC 可将频率提升至 1.9Hz(表 11), 验证了采样式 MPC 结合递推模式 $O(1)$ 单步延迟的可行性。需要指出的是, 虽然本文在 D4RL 基准数据集上进行了验证, 但与真实机器人部署仍存在一定差距, 未来需要在真机上进一步验证。

未来工作将聚焦以下方向: 1) 实现并验证采样式 MPC(如 CEM/MPPI), 结合递推模式的 $O(1)$ 单步延迟提升控制频率; 2) 在 NVIDIA Jetson 等嵌入式硬件上验证 S4D-WM 的实际推理性能和能效; 3) 将 S4D-WM 扩展到视觉输入和奖励预测, 构建更完整的多模态世界模型; 4) 引入轻量级选择性机制, 在保持参数效率的同时增强 S4D-WM 的长程多步预测能力。

参考文献:

- [1] HANSEN N, SU H, WANG X. TD-MPC2: Scalable, robust world models for continuous control. *International Conference on Learning Representations*, 2024.
- [2] HA D, SCHMIDHUBER J. Recurrent world models facilitate policy evolution. *Advances in Neural Information Processing Systems*, 2018, 31: 2450–2462.
- [3] HOCHREITER S, SCHMIDHUBER J. Long short-term memory. *Neural Computation*, 1997, 9(8): 1735–1780.
- [4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, 30: 5998–6008.
- [5] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control. *Conference on Robot Learning*, 2023.
- [6] GU A, GOEL K, RE C. Efficiently modeling long sequences with structured state spaces. *International Conference on Learning Representations*, 2022.
- [7] GU A, GUPTA A, GOEL K, et al. On the parameterization and initialization of diagonal state space models. *Advances in Neural Information Processing Systems*, 2022, 35: 27682–27695.
- [8] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces. *International Conference on Machine Learning*, 2024.
- [9] WALEFFE R, BYRD W, VENKATARAMAN S, et al. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality. *International Conference on Machine Learning*, 2024.
- [10] HAFNER D, LILLICRAP T, BA J, et al. Dream to control: Learning behaviors by latent imagination. *Advances in Neural Information Processing Systems*, 2019, 32: 1217–1228.
- [11] HAFNER D, PASUKONIS J, BA J, et al. Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*, 2023.
- [12] NAGABANDI A, KAHN G, FEARING R S, et al. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *IEEE International Conference on Robotics and Automation*, 2018: 3543–3550.
- [13] ZHANG Yi-gang, HUANG Dao-ping, LIU Yi-qi. Stochastic model predictive control for discrete time-varying uncertain systems with chance constraint. *Control Theory & Applications*, 2025, 42(12): 2459–2467.
(张逸刚, 黄道平, 刘乙奇. 受概率约束的离散时变不确定系统的随机模型预测控制. *控制理论与应用*, 2025, 42(12): 2459–2467.)
- [14] WANG Juan, ZHAO Cheng-jing, YANG Zhi-jie. Trajectory tracking control of quadcopter UAV based on MPC iterative learning. *Control Theory & Applications*, 2025, 42(12): 2528–2534.
(王娟, 赵成璟, 杨智杰. 基于 MPC 迭代学习的四旋翼无人机轨迹跟踪控制. *控制理论与应用*, 2025, 42(12): 2528–2534.)
- [15] WARDEN P, SITUNAYAKE D. TinyML: Machine learning with TensorFlow Lite on Arduino and ultra-low-power microcontrollers. *O'Reilly Media*, 2019.
- [16] HU Y, WANG W, LI L, et al. A survey on world models for autonomous driving. *arXiv preprint arXiv:2403.02622*, 2024.
- [17] GU A, DAO T, ERMON S, et al. HiPPO: Recurrent memory with optimal polynomial projections. *Advances in Neural Information Processing Systems*, 2020, 33: 1474–1487.
- [18] SMITH J T, WARRINGTON A, LINDERMAN S W. Simplified state space layers for sequence modeling. *International Conference on Learning Representations*, 2023.

- [19] FU D, DAO T, SAAB K, et al. Hungry hungry hippos: Towards language modeling with state space models. *International Conference on Learning Representations*, 2023.
- [20] SHANG J, LI X, ZHANG Y, et al. Mamba policy: Selective state space models for robot visuomotor policy. *IEEE Robotics and Automation Letters*, 2025, 10(3): 2345–2352.
- [21] OTA T. Decision Mamba: Reinforcement learning via sequence modeling with selective state spaces. *arXiv preprint arXiv:2403.19925*, 2024.
- [22] AHAMED M A, CHENG Q. TimeMachine: A time series is worth 4 Mambas for long-term forecasting. *European Conference on Artificial Intelligence*, 2024: 1688–1695.
- [23] LIU J, LIU M, WANG Z, et al. RoboMamba: Efficient vision-language-action model for robotic reasoning and manipulation. *arXiv preprint arXiv:2406.04339*, 2024.
- [24] CHUA K, CALANDRA R, MCALLISTER R, et al. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *Advances in Neural Information Processing Systems*, 2018, 31: 4754–4765.
- [25] WANG Ding-chao, LI Xi-hong, HE De-feng, et al. Distributed EMPC of nonlinear systems with communication delays. *Control Theory & Applications*, 2025, 42(12): 2449–2458.
(王定超, 李西宏, 何德峰, 等. 通信时滞非线性系统分布式经济模型预测控制. *控制理论与应用*, 2025, 42(12): 2449–2458.)
- [26] HENDRYCKS D, GIMPEL K. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016.
- [27] LOSCHILLOV I, HUTTER F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019.
- [28] FU J, KUMAR A, NACHUM O, et al. D4RL: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020.
- [29] GAO H Y. Wavelet shrinkage denoising using the non-negative garrote. *Journal of Computational and Graphical Statistics*, 1998, 7(4): 469–488.
- [30] RUBINSTEIN R Y, KROESE D P. The Cross-Entropy Method: A Unified Approach to Combinatorial Optimization, Monte-Carlo Simulation, and Machine Learning. *Springer*, 2004.
- [31] WILLIAMS G, ALDIGER A, PANDYA R, et al. Information theoretic MPC for model-based reinforcement learning. *IEEE International Conference on Robotics and Automation*, 2017: 1714–1721.

作者简介:

周新民 博士, 教授, 博士生导师, CCF 杰出会员, 主要从事具身智能、智能数据、AI 大模型等方面的研究. E-mail: zhouxinmin2699@163.com;

余焕杰 硕士研究生, CCF 学生会员, 主要从事 AI 大模型、计算机视觉等方面的研究. E-mail: semhaqx@gmail.com;

张慧慧 硕士研究生, CCF 学生会员, 主要从事智慧交通、数据分析等方面的研究. E-mail: huihuiz054@gmail.com;

王伟 硕士研究生, CCF 学生会员, 主要从事多智能体协同决策、智能体隐私保护等方面的研究. E-mail: 1819698361@qq.com;

陈露 硕士研究生, CCF 学生会员, 主要从事智能网联汽车协同感知、智慧交通等方面的研究. E-mail: 1604554843@qq.com.